

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Kevin Foreman Hutahaeen (24031554095)
Anggota 1	Kartika Nur Savira (24031554049)
Anggota 2	Diyanti Pratiwi (24031554016)
URL Github	https://github.com/Kartika-Nur-Savira/ML_Project9/tree/main


Informasi Umum Proyek

Judul	Klasifikasi Status Kesehatan Berdasarkan Faktor Gaya Hidup Menggunakan Metode <i>Ensemble Learning</i>
Topik	<i>Big Data Kesehatan</i>
Pilihan Rumusan Masalah	2.6 Pemanfaatan AI dan Big Data Kesehatan
Revisi?	Ya / Tidak

Pendahuluan

Latar belakang (≥ 250 kata)	Status kesehatan umum (<i>general health</i>) seseorang merupakan cerminan menyeluruh dari kondisi fisik, mental, gaya hidup yang dijalannya sehari-hari terbukti menjadi prediktor kuat terhadap kematian dini, kejadian penyakit, serta tingginya biaya pengobatan [1]. Indonesia sebagai negara dengan jumlah penduduk lebih dari 270 juta jiwa menghadapi tantangan besar dalam pemantauan status kesehatan masyarakat secara menyeluruh, terutama di wilayah-wilayah yang memiliki keterbatasan akses terhadap fasilitas pelayanan kesehatan. Kondisi ini menyebabkan banyak individu tidak memiliki rekam medis atau data riwayat penyakit yang lengkap, sehingga pendekatan prediksi yang bergantung pada data klinis menjadi sulit diterapkan secara luas. Peneliti sebelumnya menunjukkan bahwa faktor-faktor non-klinis seperti aktivitas fisik, status sosial ekonomi, dan perilaku kesehatan memiliki peran penting yang sangat signifikan terhadap status kesehatan, bahkan tanpa bergantung pada data riwayat penyakit [1], [3]. Temuan ini membuka peluang untuk mengembangkan model prediksi status kesehatan berbasis data yang mudah diperoleh tanpa prosedur medis, yang sangat relevan dengan Riset Kesehatan Dasar (Riset Kesehatan Dasar). Oleh karena itu, penelitian ini berfokus pada prediksi status kesehatan hanya berdasarkan informasi yang dapat diperoleh tanpa diagnosis medis menggunakan perbandingan algoritma <i>Logistic Regression</i>, <i>Random Forest</i>, dan <i>XGBoost</i> untuk mengklasifikasikan ‘<i>GeneralHealth</i>’. Jika terbukti efektif, pendekatan ini berpotensi diadaptasi ke dalam sistem pemantauan kesehatan masyarakat di Indonesia, membantu tenaga kesehatan dan pembuat kebijakan dalam mengidentifikasi masyarakat berisiko secara lebih cepat dan efisien
Rumusan masalah dan tujuan	1. Rumusan Masalah Penelitian ini merumuskan masalah-masalah utama guna memberikan kontribusi bagi kemajuan sistem kesehatan Indonesia dan kesejahteraan masyarakat luas. Berikut rumusan masalah penelitian secara menyeluruh:

	1. Bagaimana membangun model klasifikasi kesehatan umum yang akurat dan efisien sebagai bentuk dukungan terhadap program pemantauan kesehatan masyarakat dan pencegahan penyakit tidak menular yang menjadi prioritas Kementerian Kesehatan Republik Indonesia? 2. Bagaimana performa komparatif dari masing-masing algoritma menggunakan matriks evaluasi seperti <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i>, <i>F1-Score</i>, dan <i>Confusion Matrix</i> untuk memperoleh model terbaik 3. Faktor gaya hidup dan kondisi fisik apa saja yang paling dominan memengaruhi kesehatan umum seseorang berdasarkan analisis <i>Feature Importance</i> dari model terbaik? 4. Bagaimana kecerdasan buatan dapat menyediakan bukti ilmiah untuk membantu identifikasi kelompok masyarakat berisiko di daerah yang minim tenaga ahli kesehatan? 2. Tujuan Penelitian ini bertujuan untuk memberikan kontribusi bagi kemajuan sistem kesehatan indonesia dan kesejahteraan masyarakat luas. Berikut tujuan penelitian secara menyeluruh : 1. Membangun model klasifikasi kesehatan umum yang akurat dan efisien sebagai bentuk dukungan terhadap program pemantauan kesehatan masyarakat dan pencegahan penyakit tidak menular yang menjadi prioritas Kementerian Kesehatan Republik Indonesia. 2. Membandingkan performa masing-masing algoritma menggunakan matrik evaluasi seperti <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i>, <i>F1-Score</i>, dan <i>Confusion Matrix</i> untuk memperoleh model terbaik. 3. Mengidentifikasi faktor-faktor gaya hidup dan kondisi fisik yang paling dominan memengaruhi kesehatan umum seseorang menggunakan analisis Feature Importance, sehingga hasilnya dapat menjadi referensi bagi tenaga kesehatan dan pembuat kebijakan dalam merancang program intervensi kesehatan yang lebih tepat sasaran. 4. Menyediakan bukti ilmiah yang mendukung penerapan kecerdasan buatan di bidang kesehatan Indonesia untuk membantu identifikasi kelompok masyarakat berisiko rendah hingga tinggi berdasarkan kondisi kesehatannya, khususnya di daerah yang memiliki keterbatasan tenaga ahli kesehatan, sehingga dapat mendukung upaya promotif dan preventif dalam menekan angka kesakitan.
Metodologi	
Ringkasan dataset	Dataset yang digunakan adalah <i>Behavioral Risk Factor Surveillance System (BRFSS)</i> 2022 yang dipublikasikan oleh CDC (<i>Centers for Disease Control and Prevention</i>) Amerika Serikat, yang dapat diakses melalui platform Kaggle. Dataset ini berisi data survei kesehatan masyarakat tahunan yang mencakup ratusan ribu responden. Dari keseluruhan kolom yang tersedia, penelitian ini hanya menggunakan 23 fitur non-klinis yang dapat diperoleh tanpa diagnosis medis, yaitu informasi demografis (usia, jenis kelamin, ras/etnis, negara bagian), indikator gaya hidup (aktivitas fisik, jam tidur, status merokok, konsumsi alkohol, penggunaan rokok elektrik), kondisi fisik (BMI, tinggi badan, berat badan, kesulitan berjalan, gigi yang dicabut), serta riwayat pemeriksaan kesehatan (waktu check-up terakhir, tes HIV, vaksin flu, vaksin pneumonia, vaksin tetanus). Variabel target yang diprediksi adalah GeneralHealth, yaitu status kesehatan umum yang memiliki 5 kategori ordinal: <i>Poor</i>, <i>Fair</i>, <i>Good</i>, <i>Very Good</i>, dan <i>Excellent</i>.
Alur penelitian	Berikan ilustrasi (flowchart atau BPMN chart) yang meringkas proses pengolahan data untuk menyelesaikan permasalahan yang diangkat. Tuliskan deskripsi lengkap pada tiap langkah.



Gambar 1. Diagram Alur

1. Indicators of Heart Disease

Penelitian diawali dengan menentukan variabel target yang akan diprediksi, yaitu GeneralHealth sebagai indikator kondisi kesehatan umum seseorang. Prediksi dilakukan menggunakan berbagai faktor non-klinis seperti karakteristik demografis, gaya hidup, kondisi fisik, dan riwayat pemeriksaan kesehatan yang dapat diperoleh tanpa diagnosis medis.

2. Exploratory Data Analysis (EDA)

Tahap EDA dilakukan untuk memahami karakteristik dataset sebelum proses pengolahan data lebih lanjut. Analisis ini membantu mengidentifikasi permasalahan data serta memperoleh gambaran awal mengenai hubungan antar variabel.

a. Cek Tipe Data

Pemeriksaan tipe data dilakukan untuk memastikan setiap fitur memiliki format yang sesuai, seperti numerik atau kategorikal. Informasi ini diperlukan untuk menentukan teknik preprocessing yang akan digunakan pada masing-masing fitur.

b. Cek Missing Value

Pemeriksaan missing value dilakukan untuk mengetahui keberadaan data yang hilang pada setiap fitur. Hasil analisis ini digunakan sebagai dasar dalam menentukan strategi penanganan missing value yang sesuai [4].

c. Cek Imbalance

Pemeriksaan ketidakseimbangan kelas dilakukan pada variabel target untuk mengetahui apakah distribusi data antar kelas seimbang atau didominasi oleh kelas tertentu. Informasi ini penting karena

	ketidakseimbangan kelas dapat memengaruhi kemampuan model dalam melakukan prediksi [6]. d. Distribusi Fitur dan Target Analisis distribusi dilakukan untuk memahami pola penyebaran data pada setiap fitur dan variabel target. Tahap ini membantu mengidentifikasi karakteristik data seperti kemiringan distribusi, dominasi kategori tertentu, maupun pola-pola lain yang dapat memengaruhi proses pemodelan. e. Cek Outlier Pemeriksaan outlier dilakukan untuk mengidentifikasi nilai-nilai ekstrem yang berada jauh dari mayoritas data. Outlier perlu dianalisis karena dapat memengaruhi distribusi data dan performa model yang dibangun [5]. f. Korelasi Antar Fitur Analisis korelasi dilakukan untuk mengetahui tingkat hubungan antar variabel. Tahap ini membantu mengidentifikasi fitur-fitur yang memiliki hubungan kuat sehingga dapat menjadi pertimbangan dalam proses seleksi fitur dan interpretasi model. g. Cek Duplikat Pemeriksaan duplikat dilakukan untuk mengidentifikasi baris data yang identik. Data duplikat perlu dihapus untuk menghindari bias pada proses pembelajaran model [5]. 3. Split Data 80:20 Dataset yang telah melalui tahap preprocessing dibagi menjadi data latih (<i>training set</i>) dan data uji (<i>testing set</i>) dengan rasio 80:20. Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengevaluasi kemampuan model pada data yang belum pernah dilihat sebelumnya. 4. Preprocessing Tahap preprocessing bertujuan untuk meningkatkan kualitas data agar lebih siap digunakan dalam proses pelatihan model machine learning. Pada tahap ini dilakukan pembersihan data serta transformasi fitur sesuai kebutuhan algoritma. a. Data Cleaning - Handling Missing Value Data yang memiliki nilai hilang ditangani menggunakan teknik yang sesuai berdasarkan jenis datanya. Langkah ini dilakukan agar seluruh data dapat dimanfaatkan secara optimal tanpa kehilangan informasi yang penting [5]. - Handling Outlier Outlier dianalisis untuk menentukan apakah perlu dipertahankan atau ditangani lebih lanjut. Outlier diidentifikasi menggunakan metode IQR dan divisualisasikan melalui boxplot. Keputusan penanganan disesuaikan dengan karakteristik data dan tujuan penelitian [6]. - Duplikasi Data yang memiliki informasi identik diperiksa dan dihapus untuk menghindari bias akibat pengulangan observasi yang sama [5]. b. Feature Engineering - Feature Scaling
--	--

	Fitur numerik distandarisasi menggunakan StandardScaler agar memiliki rata-rata 0 dan standar deviasi 1, sehingga perbedaan rentang nilai antar fitur tidak memengaruhi proses pembelajaran model [6]. - Feature Selection Pemilihan fitur dilakukan untuk mempertahankan variabel yang relevan terhadap target serta mengurangi fitur yang kurang memberikan kontribusi terhadap proses prediksi. - Encoding Variabel kategorikal diubah menjadi representasi numerik agar dapat diproses oleh algoritma machine learning yang umumnya hanya menerima input berupa angka [4]. 5. SMOTE SMOTE (<i>Synthetic Minority Oversampling Technique</i>) digunakan untuk mengatasi ketidakseimbangan kelas pada data latih. Metode ini bekerja dengan menghasilkan sampel sintetis pada kelas minoritas berdasarkan kedekatan jarak antar data (<i>k-nearest neighbors</i>) sehingga distribusi data menjadi lebih seimbang dan model dapat mempelajari seluruh kelas dengan lebih baik [6]. 6. EDA Post-Processing Setelah seluruh proses preprocessing dan penyeimbangan data selesai dilakukan, dilakukan analisis ulang terhadap dataset hasil transformasi. Tahap ini bertujuan untuk memastikan bahwa proses preprocessing telah berjalan dengan baik dan menghasilkan data yang siap digunakan dalam pemodelan. 7. Modeling Pada tahap ini dibangun empat model klasifikasi untuk memprediksi variabel target GeneralHealth. Pemilihan keempat algoritma ini didasarkan pada karakteristik dataset yang berskala besar, memiliki fitur campuran numerik dan kategorikal, serta distribusi kelas yang tidak seimbang. a. Logistic Regression digunakan sebagai model <i>baseline</i> karena sederhana, cepat, dan mudah diinterpretasikan. Model ini bekerja dengan menghitung probabilitas suatu data masuk ke kelas tertentu menggunakan fungsi sigmoid, kemudian mengklasifikasikannya berdasarkan nilai ambang batas (<i>threshold</i>). Model ini berguna sebagai tolok ukur performa awal sebelum model yang lebih kompleks diterapkan [6]. b. Random Forest dipilih karena mampu menangani data berdimensi tinggi dan <i>robust</i> terhadap <i>outlier</i>. Model ini bekerja dengan membangun banyak pohon keputusan secara paralel menggunakan teknik <i>bagging</i>, di mana setiap pohon dilatih pada subset data yang berbeda. Hasil prediksi dari seluruh pohon kemudian digabungkan melalui voting mayoritas untuk menghasilkan prediksi akhir yang lebih stabil dan akurat [6]. c. XGBoost dipilih karena merupakan algoritma <i>boosting</i> yang dikenal unggul dalam menangani ketidakseimbangan kelas dan data tabular berskala besar. Berbeda dengan Random Forest, XGBoost membangun pohon secara bertahap (<i>sequential</i>) di mana setiap pohon baru berfokus memperbaiki kesalahan prediksi dari pohon sebelumnya menggunakan pendekatan <i>gradient descent</i>. Pendekatan ini membuat XGBoost lebih efisien dan akurat pada banyak kasus klasifikasi [5].
--	--

	d. CatBoost dipilih karena dirancang khusus untuk menangani fitur kategorikal secara efisien menggunakan teknik <i>ordered boosting</i> dan <i>target statistics</i> tanpa memerlukan <i>encoding</i> manual yang ekstensif. Hal ini menjadikan CatBoost sangat cocok untuk dataset ini yang memiliki banyak fitur kategorikal, sekaligus mengurangi risiko <i>data leakage</i> yang umum terjadi pada proses <i>encoding</i> konvensional [4]. 8. Evaluation and Compare Model Setelah seluruh model dilatih, dilakukan evaluasi menggunakan metrik <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i>, dan <i>F1-Score</i> untuk mengukur kualitas prediksi dari masing-masing model [6]. Hasil evaluasi kemudian dibandingkan untuk menentukan model yang memberikan performa terbaik pada dataset yang digunakan. Berikut rumus dari masing-masing metrik evaluasi yang digunakan: - <i>Accuracy</i> mengukur proporsi prediksi yang benar dari seluruh data: $Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)}$ - <i>Precision</i> mengukur seberapa tepat model dalam memprediksi kelas positif: $Precision = \frac{TP}{(TP + FP)}$ - <i>Recall</i> mengukur kemampuan model dalam mendeteksi seluruh data yang benar-benar positif: $Recall = \frac{TP}{(TP + FN)}$ - <i>F1-Score</i> merupakan rata-rata harmonik dari <i>Precision</i> dan <i>Recall</i>, digunakan ketika keseimbangan antara keduanya penting: $F1-Score = 2 \times \frac{(Precision \times Recall)}{(Precision + Recall)}$ Keterangan: - TP (<i>True Positive</i>): data positif yang diprediksi benar sebagai positif - TN (<i>True Negative</i>): data negatif yang diprediksi benar sebagai negatif - FP (<i>False Positive</i>): data negatif yang salah diprediksi sebagai positif - FN (<i>False Negative</i>): data positif yang salah diprediksi sebagai negatif 9. Insight dan Visualisasi Tahap terakhir dilakukan untuk menginterpretasikan hasil yang diperoleh dari model. Visualisasi digunakan untuk mempermudah pemahaman terhadap pola data, faktor-faktor yang memengaruhi prediksi, serta temuan penting yang dapat memberikan manfaat bagi pengambilan keputusan dan penelitian selanjutnya.
Proses <i>wrangling</i>	Proses <i>wrangling</i> dilakukan secara berurutan mulai dari pemilihan fitur, pengecekan kondisi data, pembersihan, hingga pembagian dataset. Berikut penjelasan tiap langkahnya beserta kode yang relevan. 1. Seleksi Fitur Non-Klinis Dari dataset yang tersedia, dipilih 23 kolom yang informasinya dapat diperoleh tanpa memerlukan diagnosis medis. Kolom-kolom tersebut berisi data demografis, gaya hidup, kondisi fisik, serta riwayat pemeriksaan

kesehatan umum. Sementara itu, kolom GeneralHealth dipilih sebagai variabel target yang akan diprediksi dalam penelitian ini.

```

1 import pandas as pd
2 non_penyakit = [
3     "State", "Sex", "LastCheckupTime", "PhysicalActivities", "SleepHours",
4     "RemovedTeeth", "SmokerStatus", "ECigaretteUsage", "ChestScan",
5     "RaceEthnicityCategory", "AgeCategory", "HeightInMeters", "WeightInKilograms",
6     "BMI", "AlcoholDrinkers", "HIVTesting", "FluVaxLast12", "PneumoVaxEver",
7     "TetanusLast10Tdap", "HighRiskLastYear", "PhysicalHealthDays", "MentalHealthDays",
8     "DifficultyWalking", "GeneralHealth"
9 ]
10 df = df[non_penyakit]
11 df.head()

```

2. Pengecekan Awal Data (EDA Awal)

Sebelum preprocessing, tim melakukan pengecekan kondisi data secara menyeluruh:

a. Cek Tipe Data

Pengecekan data menunjukkan dataset memiliki 24 kolom yang terdiri dari 18 fitur kategorikal (object) dan 6 fitur numerik (float64). Hasil ini memberikan *insight* bahwa seluruh fitur kategorikal wajib diubah menjadi angka lewat proses *encoding* agar bisa diproses oleh model *Machine Learning*.

Tabel 1. Tipe Data

No	Kolom	Non-Null Count	Tipe Data
1	State	445,132	Object
2	Sex	445,132	Object
3	LastCheckupTime	436,824	Object
4	PhysicalActivities	444,039	Object
5	SleepHours	439,679	Float64
6	RemovedTeeth	433,772	Object
7	SmokerStatus	409,670	Object
8	ECigaretteUsage	409,472	Object
9	ChestScan	389,086	Object
10	RaceEthnicityCategory	431,075	Object
11	AgeCategory	436,053	Object
12	HeightInMeters	416,480	Float64
13	WeightInKilograms	403,054	Float64
14	BMI	396,326	Float64
15	AlcoholDrinkers	398,558	Object
16	HIVTesting	379,005	Object
17	FluVaxLast12	398,011	Object
18	PneumoVaxEver	368,092	Object
19	TetanusLast10Tdap	362,616	Object
20	HighRiskLastYear	394,509	Object
21	PhysicalHealthDays	434,205	Float64
22	MentalHealthDays	436,065	Float64
23	DifficultyWalking	421,120	Object
24	GeneralHealth	443,934	Object

b. Missing Value & Sparsity


Pengecekan missing value dilakukan pada seluruh kolom dataset yang sudah di seleksi menggunakan kode berikut.

```

missing = df.isnull().sum().sort_values(ascending=False)
missing_percent = (missing / len(df)) * 100

```

	Tabel 2. Missing Value Pada Dataset			
	No	Kolom	Jumlah	Persentase (%)
	1	TetanusLast10Tdap	82.516	18,54
	2	PneumoVaxEver	77.040	17,31
	3	HIVTesting	66.127	14,86
	4	ChestScan	56.046	12,59
	5	HighRiskLastYear	50.623	11,37
	6	BMI	48.806	10,96
	7	FluVaxLast12	47.121	10,59
	8	AlcoholDrinkers	46.574	10,46
	9	WeightInKilograms	42.078	9,45
	10	ECigaretteUsage	35.660	8,01
	11	SmokerStatus	35.462	7,97
	12	HeightInMeters	28.652	6,44
	13	DifficultyWalking	24.012	5,39
	14	RaceEthnicityCategory	14.057	3,16
	15	RemovedTeeth	11.360	2,55
	16	PhysicalHealthDays	10.927	2,45
	17	AgeCategory	9.079	2,04
	18	MentalHealthDays	9.067	2,04
	19	LastCheckupTime	8.308	1,87
	20	SleepHours	5.453	1,23
	21	GeneralHealth	1.198	0,27
	22	PhysicalActivities	1.093	0,25
	Berdasarkan Tabel 1, ditemukan missing value pada beberapa fitur dengan persentase yang bervariasi. Oleh karena itu, dilakukan analisis lebih lanjut terhadap tingkat sparsity dataset untuk mengetahui seberapa besar proporsi data yang hilang secara keseluruhan dan menentukan strategi penanganan yang sesuai. <pre> 1 sparsity = (df.isnull().sum().sum() / (df.shape[0] * df.shape[1])) * 100 2 print(f"Persentase sparsity data: {sparsity:.2f}%") </pre> Hasil perhitungan menunjukkan bahwa tingkat sparsity dataset sebesar 6,66% yang berarti sekitar 93,34% data masih terisi. Nilai ini menunjukkan bahwa sebagian besar informasi dalam dataset masih tersedia sehingga data tetap layak digunakan dan missing value yang ada dapat ditangani melalui proses imputasi maupun dihapus untuk variabel target.			
	c. Duplikasi Pemeriksaan duplikasi dilakukan menggunakan kode berikut. <pre>df.duplicated().sum()</pre> Pada dataset ditemukan data duplikat sejumlah 351, selanjutnya data yang duplikat akan ditangani pada preprocessing.			
	d. Outlier Pengecekan outlier dilakukan pada fitur numerik menggunakan visualisasi boxplot.			




Gambar 1. Boxplot Hasil Deteksi Outlier

Ditemukan beberapa nilai ekstrem pada beberapa variabel numerik seperti BMI, berat badan, dan jumlah hari kesehatan fisik maupun mental terganggu. Namun nilai-nilai tersebut masih memungkinkan terjadi pada kondisi nyata responden sehingga tidak dihapus agar informasi penting tetap dipertahankan.

e. Ketidakseimbangan Kelas

Pengecekan distribusi kelas dilakukan pada variabel target GeneralHealth.



Gambar 2. Distribusi Kelas

Hasil visualisasi distribusi kelas menunjukkan bahwa jumlah data pada masing-masing kategori GeneralHealth tidak seimbang. Oleh karena itu, diperlukan tindak lanjut pada tahap preprocessing untuk mengurangi dampak ketidakseimbangan kelas sebelum proses pelatihan model dilakukan.

3. Pembersihan Data

a. Hapus Missing Value pada Target

Setelah dilakukan pengecekan terdapat 1198 baris missing value pada variabel target sehingga sebelum proses pemodelan perlu dihapus terlebih dahulu. Langkah ini diperlukan karena variabel target berfungsi sebagai label yang akan diprediksi oleh model. Apabila label tidak tersedia, data tersebut tidak dapat digunakan dalam proses pelatihan maupun evaluasi model.

b. Hapus Duplikasi

Pada dataset ditemukan data duplikat sejumlah 351, selanjutnya data yang duplikat akan dihapus karena tidak memberikan informasi baru dan berpotensi menyebabkan bias pada proses pembelajaran model.


4. Pembagian Data (Train-Test Split)


	Sebelum proses imputasi dan transformasi fitur dilakukan, dataset terlebih dahulu dibagi menjadi data train dan data test dengan rasio 80:20 menggunakan library scikit-learn, parameter <code>test_size=0.2</code> digunakan untuk mengalokasikan 20% data sebagai data uji, <code>random_state=42</code> untuk memastikan hasil pembagian dapat direproduksi, serta <code>stratify=y</code> untuk menjaga proporsi tiap kelas pada variabel target tetap seimbang. Proses pembagian dilakukan sebelum imputasi dan scaling guna mencegah terjadinya data leakage, yaitu masuknya informasi dari data uji ke proses pelatihan model.. <pre> 1 X_train, X_test, y_train, y_test = train_test_split(2 X, 3 y, 4 test_size=0.2, 5 random_state=42, 6 stratify=y 7) </pre> 5. Imputasi Missing Value (Setelah Split) Proses imputasi dilakukan secara terpisah untuk fitur numerik dan fitur kategorikal. Fitur Numerik Fitur-fitur seperti <i>BMI</i>, <i>SleepHours</i>, <i>PhysicalHealthDays</i>, <i>MentalHealthDays</i>, <i>HeightInMeters</i>, dan <i>WeightInKilograms</i>/Fitur numerik diimputasi menggunakan strategi median. Median dipilih sebagai pengganti mean karena lebih robust terhadap outlier Fitur Kategorikal Pada fitur kategorikal data yang memiliki missing value diimputasi menggunakan '<i>Unknow</i>'. Hal ini dipilih karena nilai yang hilang pada variabel kategorikal tidak dapat dengan mudah diganti dengan nilai yang paling sering muncul atau modus tanpa risiko menimbulkan bias.
Proses rekayasa fitur	Pada tahap rekayasa fitur, dilakukan transformasi terhadap variabel kategorik dan numerik agar dapat diproses secara optimal oleh algoritma machine learning, proses ini meliputi encoding variabel kategorikal, transformasi logaritmik yang bersifat skewed, serta standarisasi fitur numerik. - Encoding Binary encoding Fitur biner seperti <i>PhysicalActivities</i>, <i>ChestScan</i>, <i>AlcoholDrinkers</i>, <i>HIVTesting</i>, <i>FluVaxLast12</i>, <i>PneumoVaxEver</i>, <i>DifficultyWalking</i>, dan <i>HighRiskLastYear</i> dikonversi menggunakan pemetaan manual, yaitu nilai Yes menjadi 1, No menjadi 0, dan Unknown menjadi -1. Penggunaan nilai -1 pada kategori Unknown bertujuan agar model dapat membedakan antara jawaban negatif dan data yang tidak diketahui tanpa menghilangkan informasi. Selain itu, fitur Sex juga dikonversi secara numerik dengan nilai Female sebagai 0 dan Male sebagai 1. One-hot encoding Fitur nominal tanpa urutan alami, seperti <i>State</i>, <i>RaceEthnicityCategory</i>, dan <i>TetanusLast10Tdap</i>, diencoding menggunakan metode One-Hot Encoding (OHE). Metode ini mengubah setiap kategori menjadi kolom biner baru. Parameter <code>drop='first'</code> digunakan untuk menghindari multikolinearitas yang dapat mengganggu stabilitas algoritma (James et al., 2023). Sedangkan <code>handle_unknown='ignore'</code> memungkinkan model

	menangani kategori baru pada data uji. Proses fitting dilakukan pada data train, kemudian diterapkan pada data latih dan data uji [2]. c. Ordinal encoding Fitur ordinal seperti <i>SmokerStatus</i>, <i>ECigaretteUsage</i>, <i>LastCheckupTime</i>, <i>RemovedTeeth</i>, dan <i>AgeCategory</i> diencoding menggunakan <i>OrdinalEncoder</i> dengan urutan kategori yang ditentukan secara eksplisit agar nilai numerik mencerminkan hirarki data. Untuk menangani kategori yang tidak dikenali pada data uji, digunakan parameter <code>handle_unknown='use_encoded_value'</code> dengan <code>unknown_value=-1</code> sehingga proses transformasi tetap dapat berjalan tanpa error [4]. d. Encoding variabel target Variabel target <i>GeneralHealth</i> diencoding secara ordinal menggunakan <i>OrdinalEncoder</i> dengan urutan Poor (0), Fair (1), Good (2), Very Good (3), dan Excellent (4). Penggunaan encoding ordinal dilakukan agar model dapat memahami hubungan urutan antar kelas tingkat kesehatan. 2. Transformasi Fitur Numerik a. Log transformation untuk fitur skewed Fitur <i>PhysicalHealthDays</i> dan <i>MentalHealthDays</i> yang memiliki distribusi miring ke kanan ditransformasi menggunakan fungsi <code>log1p</code>. Transformasi ini dipilih karena aman untuk nilai nol serta mampu mengurangi kemiringan distribusi sehingga data menjadi lebih mendekati distribusi normal dan lebih sesuai untuk proses pemodelan machine learning. b. Standart Scaler Seluruh fitur numerik kontinu, yaitu <i>SleepHours</i>, <i>HeightInMeters</i>, <i>WeightInKilograms</i>, <i>BMI</i>, <i>PhysicalHealthDays</i>, dan <i>MentalHealthDays</i>, diskalakan menggunakan <i>StandardScaler</i> agar memiliki rata-rata 0 dan standar deviasi 1. Proses fitting dilakukan pada data latih, kemudian transformasi diterapkan pada data latih dan data uji untuk mencegah data <i>leakage</i>. Visualisasi distribusi sebelum dan sesudah scaling digunakan untuk memverifikasi hasil transformasi. 3. Validasi Akhir Pada tahapan ini setelah seluruh proses preprocessing selesai, dilakukan pengecekan akhir untuk memastikan tidak ada lagi missing value pada seluruh kolom data train.
Temuan	Berdasarkan keseluruhan proses manipulasi data, rekayasa fitur, hingga penyeimbangan data (<i>post-processing</i>) yang telah dilakukan, ditemukan beberapa karakteristik data penting sebagai berikut: 1. Temuan Hasil Penanganan <i>Missing Value</i> pada Fitur Kategorikal dan Numerik Berdasarkan hasil eksekusi kodingan pengecekan data di <i>notebook</i>, ditemukan bahwa <i>missing value</i> tersebar di 22 kolom dengan persentase bervariasi hingga mencapai 18,54%. Melalui fungsi perulangan (<i>looping</i>) yang dibuat di <i>notebook</i>, tim menangani seluruh data kosong ini secara otomatis berdasarkan tipe datanya: semua kolom dengan tipe objek/kategorikal langsung diimputasi dengan teks 'Unknown' (nilai -1), sedangkan seluruh kolom dengan tipe numerik otomatis diisi menggunakan nilai <i>median</i> dari data latih. <i>Insight</i> dari penerapan kode ini adalah proses pembersihan data berskala besar menjadi jauh lebih efisien dan konsisten,

	serta menghindari manipulasi data yang bisa merusak pola asli jawaban ratusan ribu responden survei. 2. Temuan Efek Transformasi Logaritma pada Kolom Hari Sakit (Physical/MentalHealthDays) Pada tahapan rekayasa fitur, ditemukan bahwa kolom PhysicalHealthDays dan MentalHealthDays memiliki distribusi data yang sangat miring ke kanan (<i>skewed</i>). Hal ini terjadi karena mayoritas responden mengisi angka 0 (artinya mereka tidak merasa sakit dalam sebulan terakhir), sementara hanya sedikit yang mengisi angka besar. Masalah ini berhasil diatasi di kodingan menggunakan fungsi transformasi logaritma $\log(1+p)$. <i>Insight</i> dari proses ini adalah mengubah skala data menjadi logaritma berhasil memperkecil jarak rentang nilai yang terlalu jauh tanpa harus menghapus data ekstrem tersebut, sehingga persebaran data jadi lebih rapi dan lebih siap saat diproses oleh algoritma seperti <i>Logistic Regression</i> dan model <i>tree</i>. 3. Temuan <i>Imbalance</i> Data serta Penyeimbangan Kelas Target (SMOTE) Meskipun alur pemrosesan data dan fungsi SMOTE (<i>Synthetic Minority Oversampling Technique</i>) yang digunakan pada kedua <i>notebook</i> memiliki struktur kode yang identik, isi dari sintesis penyeimbangan data mengalami perbedaan mendasar akibat perbedaan perlakuan pada dimensi variabel target GeneralHealth. Pada Notebook 1, SMOTE mengeksekusi penyeimbangan pada kondisi target asli yang berskala <i>multiclass</i> (5 kategori) sehingga prosesnya bekerja lebih kompleks di ruang dimensi tinggi untuk menyintesis sampel tiruan pada setiap kategori minoritas agar setara dengan kategori mayoritas guna mencegah model <i>baseline</i> mengalami bias klasifikasi global. Sementara pada Notebook 2, fungsi SMOTE dioperasikan setelah variabel target melalui tahap pengelompokkan ulang (<i>re-mapping</i>) menjadi skala biner (2 kategori) yang memberikan <i>insight</i> bahwa implementasi SMOTE pada struktur biner menghasilkan batas keputusan (<i>decision boundary</i>) yang jauh lebih terarah karena fokus komputasi hanya dibagi menjadi dua domain utama, sehingga sangat membantu meningkatkan metrik sensitivitas (<i>Recall</i>) pada model <i>ensemble</i> lanjutan.
--	---


Hasil dan Pembahasan

Hasil eksplorasi data	 Gambar 2. Korelasi Antar Fitur Berdasarkan Gambar 2, korelasi positif terkuat ditemukan antara variabel WeightInKilograms dan BMI karena faktor hubungan matematis, diikuti hubungan moderat antara tinggi-berat badan serta antara PhysicalHealthDays dengan MentalHealthDays. Sementara itu, variabel SleepHours menunjukkan korelasi negatif lemah terhadap hari gangguan kesehatan serta tidak memiliki keterkaitan statistik yang signifikan dengan karakteristik fisik seperti tinggi maupun berat badan.
-----------------------	---




Gambar 3. Distribusi Fitur Terhadap Target Sebelum Preprocessing

Berdasarkan gambar 3, terlihat perbedaan distribusi fitur numerik terhadap target masih berada pada skala aslinya dan menunjukkan perbedaan rentang nilai antar fitur. Fitur BMI, WeightInKilograms, PhysicalHealthDays, dan MentalHealthDays menunjukkan perbedaan pola distribusi antar kelas GeneralHealth, sedangkan SleepHours dan HeightInMeters memiliki distribusi yang relatif mirip pada setiap kelas.



Gambar 4. Distribusi Fitur Terhadap Target setelah Preprocessing

Berdasarkan gambar 4, setelah preprocessing dilakukan dapat dilihat bahwa preprocessing berhasil menyamakan skala seluruh fitur sehingga distribusi data menjadi lebih terpusat dan seragam. Meskipun skala data berubah, pola distribusi tetap dipertahankan, Fitur BMI, WeightInKilograms, PhysicalHealthDays, dan MentalHealthDays masih menunjukkan variasi antar kelas GeneralHealth, sehingga berpotensi memberikan kontribusi dalam proses klasifikasi.




Gambar 5. Distribusi kelas sebelum dan sesudah SMOTE

Gambar 5 menunjukkan perbandingan distribusi kelas variabel target GeneralHealth sebelum dan setelah penerapan SMOTE. Sebelum SMOTE, distribusi kelas sangat tidak seimbang. Kelas Very Good mendominasi dengan 118.612 sampel, diikuti Good (114.820), Excellent (57.425), Fair (48.216), dan

Poor yang hanya berjumlah 15.793 sampel. Ketidakseimbangan ini berpotensi membuat model cenderung memprediksi kelas mayoritas dan mengabaikan kelas minoritas seperti *Poor* dan *Fair*.

Setelah SMOTE diterapkan, seluruh kelas memiliki jumlah sampel yang sama yaitu 118.612. SMOTE bekerja dengan membangkitkan sampel sintesis pada kelas minoritas berdasarkan kedekatan antar data, bukan sekedar menduplikasi data yang sudah ada. Hasilnya, model memiliki kesempatan yang sama untuk mempelajari pola dari seluruh kelas sehingga diharapkan kemampuan prediksi pada kelas minoritas seperti *Poor* dan *Fair* dapat meningkat secara signifikan.



Gambar 6. Perbandingan Distribusi Kelas Sebelum dan Setelah SMOTE (Skenario 2)

Selain itu dilakukan skenario kedua seperti pada Gambar 6 yaitu menyederhanakan label target menjadi 3 kelas untuk mengurangi kompleksitas klasifikasi. Kelas *Poor* dan *Fair* digabungkan menjadi satu kelas baru berlabel *Poor*, kelas *Good* diubah menjadi *Fair*, serta kelas *Very Good* dan *Excellent* digabungkan menjadi kelas *Good*. Penggabungan ini didasarkan pada kedekatan semantik antar kelas yang berdekatan, sehingga batas antar kelas menjadi lebih tegas dan model diharapkan lebih mudah membedakan kondisi kesehatan secara umum.

Sebelum SMOTE diterapkan, distribusi tiga kelas baru tersebut tetap tidak seimbang, dengan kelas *Poor* (gabungan *Poor* dan *Fair*) berjumlah 64.009 sampel, *Fair* (dari *Good*) sebanyak 114.820 sampel, dan *Good* (gabungan *Very Good* dan *Excellent*) sebanyak 176.037 sampel. Setelah SMOTE diterapkan, seluruh kelas diseimbangkan menjadi 176.037 sampel, sehingga model memiliki representasi yang proporsional terhadap ketiga kelas dan diharapkan mampu menghasilkan prediksi yang lebih adil dan akurat pada kelas minoritas.

Hasil eksperimen

A. Analisis dan Evaluasi Performa Model

Evaluasi model dilakukan menggunakan Classification Report yang mencakup metrik precision, recall, F1-score, dan accuracy. Pengujian bertujuan untuk mengukur kemampuan model dalam mengklasifikasikan kondisi kesehatan responden berdasarkan variabel target GeneralHealth. Evaluasi dilakukan pada dua skenario, yaitu klasifikasi multiclass menggunakan data asli pada Notebook 1 dan klasifikasi biner yang telah dioptimasi menggunakan teknik SMOTE pada Notebook 2.

1. Pada skenario pertama, model dilatih menggunakan lima kelas target asli, yaitu *Excellent*, *Fair*, *Good*, *Poor*, dan *Very Good*. Distribusi data pada masing-masing kelas tidak seimbang, yang terlihat dari perbedaan nilai *support* yang cukup besar antar kelas.

Tabel 3. Hasil Evaluasi CatBoost

Class	Precision	Recall	F1-Score	Support
0	0,52	0,41	0,46	3.948
1	0,44	0,32	0,38	12.054

2	0,45	0,51	0,48	28.705
3	0,47	0,61	0,53	29.653
4	0,47	0,19	0,27	14.357
Accuracy	-	-	0,46	88.717
Macro Avg	0,47	0,41	0,42	88.717
Weighted Avg	0,46	0,46	0,45	88.717

Berdasarkan hasil validasi pada Tabel 3, Model CatBoost menghasilkan accuracy sebesar 46%. Nilai macro recall sebesar 0.41 dan macro F1-score sebesar 0.42 menunjukkan bahwa model mampu memberikan performa yang cukup seimbang pada sebagian besar kelas. Kelas 3 memperoleh recall tertinggi sebesar 0.61 dengan F1-score sebesar 0.53, sedangkan kelas 4 memiliki recall terendah yaitu 0.19. Hasil ini menunjukkan bahwa model masih mengalami kesulitan dalam mengenali beberapa kategori kesehatan tertentu meskipun secara keseluruhan mampu menghasilkan performa yang lebih baik dibandingkan sebagian besar model lainnya.

Tabel 4. Hasil Evaluasi Logistic Regression

Class	Precision	Recall	F1-Score	Support
0	0,31	0,76	0,44	3.948
1	0,29	0,32	0,31	12.054
2	0,44	0,28	0,34	28.705
3	0,46	0,31	0,37	29.653
4	0,31	0,60	0,41	14.357
Accuracy	-	-	0,37	88.717
Macro Avg	0,36	0,45	0,37	88.717
Weighted Avg	0,40	0,37	0,36	88.717

Berdasarkan hasil validasi pada Tabel 4, Logistic Regression memperoleh accuracy sebesar 37%, yang merupakan nilai terendah dibandingkan model lainnya. Meskipun demikian, model menunjukkan kemampuan yang cukup baik dalam mengenali kelas 0 dan kelas 4 dengan recall masing-masing sebesar 0.76 dan 0.60. Sebaliknya, recall pada kelas 2 dan kelas 3 relatif rendah, yaitu 0.28 dan 0.31. Perbedaan nilai recall yang cukup besar antar kelas menunjukkan bahwa model belum mampu mempelajari seluruh kategori kesehatan secara merata pada skenario klasifikasi lima kelas.

Tabel 5. Hasil Evaluasi Random Forest

Class	Precision	Recall	F1-Score	Support
0	0,44	0,52	0,47	3.948
1	0,39	0,35	0,37	12.054
2	0,43	0,46	0,45	28.705
3	0,46	0,51	0,49	29.653
4	0,39	0,27	0,32	14.357
Accuracy	-	-	0,43	88.717
Macro Avg	0,42	0,42	0,42	88.717
Weighted Avg	0,43	0,43	0,43	88.717

Pada Tabel 5, Random Forest menghasilkan accuracy sebesar 43% dengan macro recall dan macro F1-score yang sama-sama sebesar 0.42. Model menunjukkan performa yang relatif stabil pada sebagian besar kelas dengan nilai recall berada pada rentang 0.27–0.52. Kelas 3

memperoleh recall tertinggi sebesar 0.51, sedangkan kelas 4 memiliki recall terendah sebesar 0.27. Hasil ini menunjukkan bahwa Random Forest mampu menghasilkan performa yang lebih seimbang dibandingkan Logistic Regression, meskipun masih mengalami kesulitan dalam mengidentifikasi kelas tertentu.

Tabel 6. Hasil Evaluasi Random Forest Tuned

Class	Precision	Recall	F1-Score	Support
Poor	0,44	0,52	0,48	3.948
Fair	0,39	0,34	0,37	12.054
Good	0,44	0,46	0,45	28.705
Very Good	0,46	0,52	0,49	29.653
Excellent	0,39	0,27	0,32	14.357
Accuracy	-	-	0,44	88.717
Macro Avg	0,43	0,42	0,42	88.717
Weighted Avg	0,43	0,44	0,43	88.717

Pada tabel 6, Setelah dilakukan tuning hyperparameter, Random Forest memperoleh accuracy sebesar 44%. Nilai macro recall dan macro F1-score tetap berada pada angka 0.42, sehingga peningkatan performa yang diperoleh relatif kecil dibandingkan model sebelum tuning. Kelas Very Good dan Poor memiliki recall tertinggi sebesar 0.52, sedangkan kelas Excellent masih menjadi kelas dengan recall terendah yaitu 0.27. Hasil ini menunjukkan bahwa proses tuning memberikan peningkatan yang terbatas terhadap kemampuan klasifikasi model.

Tabel 7. Hasil Evaluasi XGBoost

Class	Precision	Recall	F1-Score	Support
0	0,42	0,61	0,49	3.948
1	0,41	0,30	0,34	12.054
2	0,45	0,44	0,44	28.705
3	0,47	0,50	0,48	29.653
4	0,38	0,39	0,39	14.357
Accuracy	-	-	0,44	88.717
Macro Avg	0,43	0,45	0,43	88.717
Weighted Avg	0,44	0,44	0,44	88.717

Berdasarkan Tabel 7, XGBoost memperoleh accuracy sebesar 44% dengan macro recall sebesar 0.45 dan macro F1-score sebesar 0.43. Nilai macro recall yang lebih tinggi dibandingkan Random Forest menunjukkan bahwa XGBoost memiliki kemampuan yang lebih baik dalam mengenali seluruh kelas secara keseluruhan. Kelas 0 memperoleh recall tertinggi sebesar 0.61, sedangkan kelas 1 memiliki recall terendah sebesar 0.30. Hasil validasi menunjukkan bahwa XGBoost mampu menghasilkan performa yang cukup baik pada klasifikasi lima kelas dengan distribusi prediksi yang relatif lebih merata.

Tabel 8. Hasil Evaluasi XGBoost Tuned

Class	Precision	Recall	F1-Score	Support
Poor	0,48	0,49	0,48	3.948
Fair	0,44	0,30	0,35	12.054
Good	0,44	0,48	0,46	28.705
Very Good	0,47	0,57	0,51	29.653
Excellent	0,43	0,27	0,33	14.357

Accuracy	-	-	0,45	88.717
Macro Avg	0,45	0,42	0,43	88.717
Weighted Avg	0,45	0,45	0,44	88.717

XGBoost Tuned memperoleh hasil accuracy 45% yang dimana hasil tersebut meningkat jika dibandingkan dengan XGBoost pada tabel 7 sebelum di tuning. Model menghasilkan macro recall sebesar 0.42 dan macro F1-score sebesar 0.43. Kelas Very Good memiliki performa terbaik dengan recall 0.57 serta F1-score sebesar 0.51, sedangkan kelas Excellent memiliki recall terendah yaitu 0.27.

2. Pada skenario kedua, dilakukan penyederhanaan target menjadi tiga kelas. Perubahan ini bertujuan untuk mengurangi kompleksitas klasifikasi serta membantu model dalam mempelajari pola data dengan lebih efektif. Selanjutnya, model kembali dilatih dan divalidasi menggunakan data uji yang sama.

Tabel 9. Hasil Accuracy

Model	Accuracy
CatBoost	0,62
Logistic Regression	0,59
Random Forest	0,60
Random Forest Tuned	0,60
XGBoost	0,61
XGBoost Tuned	0,61

Pada skenario 2 dengan penyederhanaan target menjadi tiga kelas, CatBoost berhasil mencapai performa tertinggi dengan akurasi sebesar 0,62. Selanjutnya XGBoost sebesar 0,61. Sementara itu, model Random Forest (baik sebelum maupun sesudah *tuning*) dan Logistic Regression menunjukkan performa yang relatif stabil namun sedikit di bawah model berbasis *gradient boosting*, dengan akurasi masing-masing sebesar 0,60 dan 0,59. Secara keseluruhan, penyederhanaan kelas ini memberikan basis performa yang cukup kompetitif di rentang 59% hingga 62%, di mana model-model berbasis *ensemble* tingkat lanjut seperti CatBoost dan XGBoost terbukti lebih efektif dalam mempelajari pola data baru yang telah disederhanakan.

Tabel 10. Hasil Macro Recall

Model	Macro Recall
CatBoost	0,58
Logistic Regression	0,58
Random Forest	0,58
Random Forest Tuned	0,57
XGBoost	0,58
XGBoost Tuned	0,58

Pada Tabel 10, terlihat bahwa seluruh model memiliki nilai macro recall yang relatif serupa, yaitu berada pada rentang 0,57–0,58. Hal ini menunjukkan bahwa kemampuan model dalam mengenali setiap kelas secara seimbang tidak berbeda jauh. Meskipun demikian, Random Forest Tuned mengalami sedikit penurunan dibandingkan model sebelum tuning.

	Tabel 11. Hasil Macro F1-Score <table><tr><th>Model</th><th>Macro F1-Score</th></tr><tr><td>CatBoost</td><td>0,58</td></tr><tr><td>Logistic Regression</td><td>0,56</td></tr><tr><td>Random Forest</td><td>0,57</td></tr><tr><td>Random Forest Tuned</td><td>0,57</td></tr><tr><td>XGBoost</td><td>0,58</td></tr><tr><td>XGBoost Tuned</td><td>0,60</td></tr></table>	Model	Macro F1-Score	CatBoost	0,58	Logistic Regression	0,56	Random Forest	0,57	Random Forest Tuned	0,57	XGBoost	0,58	XGBoost Tuned	0,60
	Model	Macro F1-Score													
	CatBoost	0,58													
	Logistic Regression	0,56													
	Random Forest	0,57													
	Random Forest Tuned	0,57													
	XGBoost	0,58													
	XGBoost Tuned	0,60													
	Berdasarkan Tabel 11, nilai macro F1-score seluruh model berada pada rentang yang cukup berdekatan, yaitu antara 0,56 hingga 0,60. CatBoost dan XGBoost Tuned memperoleh nilai tertinggi, sementara Logistic Regression memperoleh nilai terendah sebesar 0,56. Perbedaan yang kecil ini mengindikasikan bahwa secara umum seluruh model memiliki kemampuan yang relatif setara dalam memprediksi ketiga kelas secara seimbang.														
	B. Penentuan dan Analisis Model Terbaik														
Berdasarkan seluruh rangkaian pengujian yang telah dilakukan pada Skenario 1 dan Skenario 2, dari empat algoritma yang diuji, XGBoost dengan optimasi parameter (<i>XGBoost Tuned</i>) menunjukkan performa yang paling optimal secara konsisten. Pada skenario 1 model ini berhasil mencapai akurasi 45% dan 61% pada skenario 2. Juga mendapat nilai F1-Score 43% pada skenario 1 dan 60% pada skenario 2.															
Model terbaik dipilih tidak hanya berdasarkan nilai <i>Accuracy</i> tertinggi, melainkan juga keseimbangan nilai <i>Precision</i>, <i>Recall</i>, dan <i>F1-Score</i> pada setiap kelas target guna menghindari bias akibat ketidakseimbangan data (<i>data imbalance</i>). Peningkatan performa yang drastis dari 45% ke 61% membuktikan bahwa penyederhanaan kelas target serta penanganan ketidakseimbangan data menggunakan teknik SMOTE berhasil meminimalisir bias model (<i>data imbalance</i>). Hal ini membuat XGBoost Tuned menjadi model yang paling baik dan siap direkomendasikan untuk sistem klasifikasi kesehatan umum masyarakat.															
Kesimpulan dan Saran															
Kesimpulan															
Proyek ini berhasil berkontribusi dalam menyelesaikan masalah keterbatasan akses pemantauan kesehatan masyarakat melalui pembuktian bahwa status kesehatan umum (General Health) dapat diklasifikasikan secara objektif menggunakan fitur non-klinis dan faktor gaya hidup dari dataset BRFSS 2022. Berdasarkan hasil eksperimen pada Skenario 1, penerapan teknik SMOTE langsung pada lima kategori ordinal asli menunjukkan batasan performa algoritma yang cukup signifikan, di mana model XGBoost Tuned hanya mampu meraih akurasi optimal sebesar 45%. Masalah keterbatasan pengenalan pola ini berhasil diatasi pada Skenario 2 melalui strategi restrukturisasi data, di mana kelas target disederhanakan menjadi tiga kategori utama (Poor, Fair, Good) sebelum dioptimasi menggunakan SMOTE. Rekayasa struktur data pada Skenario 2 ini terbukti efektif memberikan representasi spasial yang lebih jelas bagi algoritma sehingga berhasil mendongkrak akurasi seluruh model ensemble learning. Keberhasilan kerangka kerja ini menyediakan bukti ilmiah yang kuat bagi implementasi kecerdasan buatan sebagai sistem skrining awal kesehatan yang andal untuk mendukung program preventif Kementerian Kesehatan di daerah minim fasilitas medis.															

	Bagi masyarakat luas, proyek ini menghasilkan temuan konkret berupa identifikasi faktor risiko harian yang paling dominan mempengaruhi derajat kesehatan fisik dan mental berdasarkan analisis model, seperti Indeks Massa Tubuh (BMI), berat badan, aktivitas fisik, dan durasi tidur harian. Melalui pola prediktif yang ditemukan dalam kedua skenario eksperimen tersebut, masyarakat dapat memanfaatkan temuan ini sebagai panduan evaluasi mandiri (self-screening) berbasis gaya hidup sehari-hari untuk mendeteksi penurunan kondisi tubuh secara dini sebelum berkembang menjadi penyakit kronis. Selain itu, visualisasi analitis yang dihasilkan dari penelitian ini dapat digunakan oleh tenaga kesehatan lokal di puskesmas sebagai referensi ilmiah dan mudah dipahami oleh masyarakat dalam merancang program edukasi publik serta intervensi kesehatan preventif yang jauh lebih tepat sasaran di lingkungan masyarakat.
Saran	<i>Tuliskan saran-saran untuk penelitian berikutnya</i> 1. Kontekstualisasi Dataset Berbasis Populasi Indonesia: Dataset BRFSS 2022 yang digunakan dalam proyek ini merepresentasikan pola hidup masyarakat Amerika Serikat. Agar implementasinya lebih akurat dan relevan dengan sistem kesehatan di Indonesia. 2. Penggunaan metode penanganan Class Imbalance, pada penelitian ini penanganan imbalance data ditangani menggunakan metode SMOTE dengan teknik oversampling yaitu penambahan data sintesis pada kelas minoritas, untuk penelitian selanjutnya, disarankan untuk membandingkan efektifitas SMOTE dengan metode lain, seperti ADASYN (Adaptive Synthetic Sampling), maupun kombinasi teknik oversampling dan undersampling seperti SMOTE-Tomek dan SMOTE-ENN. Perbandingan dapat dilakukan untuk mengetahui metode mana yang paling optimal dan meningkatkan klasifikasi ordinal lima kelas tanpa melakukan penggabungan kelas target. 3. Penelitian selanjutnya dapat mempertimbangkan penambahan fitur yang lebih beragam seperti riwayat penyakit keluarga, pola makan, atau akses terhadap layanan kesehatan untuk meningkatkan kemampuan prediksi model.
Daftar Pustaka	
Daftar Pustaka	[1] C. R. Clark, M. J. Ommerborn, K. Moran, K. Brooks, J. Haas, D. W. Bates, dan A. Wright, "Predicting Self-Rated Health Across the Life Course: Health Equity Insights from Machine Learning Models," <i>Journal of General Internal Medicine</i>, vol. 36, no. 5, pp. 1181–1188, 2021, doi: 10.1007/s11606-020-06438-1. [2] M. Imani, A. Maroosi, S. Shojaei, K. Heidari, S. M. Hoseinzadeh, N. Daneshi, Z. Saber, N. Sajadi, dan M. Mohammadzadeh, "Predicting Cardiovascular Diseases Using Imbalanced Data: An XGBoost-Based Analysis of the 2022 BRFSS Dataset," <i>American Heart Journal Plus: Cardiology Research and Practice</i>, vol. 63, Art. no. 100719, 2026, doi: 10.1016/j.ahjo.2026.100719. [3] J. Hoekstra, E. S. Lenssen, A. Wong, B. Loeff, G.-C. M. Herber, H. C. Boshuizen, M. Strak, W. M. M. Verschuren, dan N. A. H. Janssen, "Predicting Self-Perceived General Health Status Using Machine Learning: An External Exposome Study," <i>BMC Public Health</i>, vol. 23, Art. no. 1027, 2023, doi: 10.1186/s12889-023-15962-8. [4] N. L. Sabili, F. R. Umbara, dan Melina, "Klasifikasi Penyakit Diabetes Menggunakan Algoritma Categorical Boosting dengan Faktor Risiko Diabetes," <i>JATI (Jurnal Mahasiswa Teknik Informatika)</i>, vol. 8, no. 6, pp. 11391–11398, Dec. 2024, doi: 10.36040/jati.v8i6.11447.

	[5] M. Salsabil, N. L. Azizah, dan A. Eviyanti, “Implementasi Data Mining dalam Melakukan Prediksi Penyakit Diabetes Menggunakan Metode Random Forest dan XGBoost,” Jurnal Ilmiah KOMPUTASI, vol. 23, no. 1, pp. 51–58, 2024, doi: 10.32409/jikstik.23.1.3507. [6] L. R. Sitompul, A. A. Nababan, M. L. Manihuruk, W. A. Ponsen, dan Supriyandi, “Comparison of XGBoost, Random Forest, and Logistic Regression Algorithms in Stroke Disease Classification,” Sinkron: Jurnal dan Penelitian Teknik Informatika, vol. 9, no. 2, pp. 957–968, 2025, doi: 10.33395/sinkron.v9i2.14794.
--	--