

Laporan Kemajuan Proyek

Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Kevin Foreman Hutahaeen (24031554095)
Anggota 1	Kartika Nur Savira (24031554049)
Anggota 2	Diyanti Pratiwi (24031554016)
URL Github	https://github.com/Kartika-Nur-Savira/ML_Project9/tree/main

Informasi Umum Proyek

Judul	Klasifikasi Status Kesehatan Berdasarkan Faktor Gaya Hidup Menggunakan Metode <i>Ensemble Learning</i>
Topik	<i>Big Data Kesehatan</i>
Pilihan Rumusan Masalah	2.6 Pemanfaatan AI dan Big Data Kesehatan
Revisi?	Ya / Tidak

Informasi Detil Dataset

Sumber dataset	https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease		
Deskripsi awal fitur dataset	Dataset yang digunakan terdiri dari 23.496 sampel dengan 39 fitur prediktor dan satu fitur target yaitu general health. Variabel target memiliki lima kelas : Poor, Fair, Good, Very Good, dan Excellent. Namun fitur yang digunakan dalam penelitian ini dibatasi pada variabel gaya hidup, kondisi fisik, dan sosiodemografi yang berjumlah 23 fitur. Variabel riwayat penyakit tidak diikutsertakan karena bersifat sebagai konsekuensi dari kondisi kesehatan, bukan faktor penentu independen, sehingga penggunaanya dapat menyebabkan data leakage secara konseptual.		
	Tabel 1. Variabel Penelitian		
	Nama Variabel	Tipe Data	Deskripsi
	<i>General Health</i>	<i>Ordinal</i>	<i>Self-reported general health status (Poor to Excellent)</i>
	BMI	<i>Float</i>	<i>Body Mass Index of respondent</i>
	<i>SleepHours</i>	<i>Float</i>	Rata-rata jam tidur per hari
	<i>PhysicalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan fisik tidak baik
	<i>MentalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan mental tidak baik
	<i>PhysicalActivities</i>	Kategorik	Menunjukkan apakah responden melakukan

	aktivitas fisik DifficultyWalking Kategorik Kesulitan berjalan atau menaiki tangga SmokerStatus Kategorik Status kebiasaan merokok responden ECigaretteUsage Kategorik Penggunaan rokok elektrik AlcoholDrinkers Kategorik Status konsumsi alkohol FluVaxLast12 Kategorik Status vaksin flu dalam 12 bulan terakhir HIVTesting Kategorik Pernah melakukan tes HIV LastCheckupTime Kategorik Waktu pemeriksaan kesehatan terakhir ChestScan Kategorik Riwayat pemeriksaan rontgen/scan dada AgeCategory Kategorik Kelompok usia Sex Kategorik Jenis kelamin responden RaceEthnicityCategory Kategorik Kategori ras/etnis responden State Kategorik Negara bagian tempat tinggal responden WeightInKilograms Float Berat badan responden dalam kilogram RemovedTeeth Kategorik Jumlah gigi yang telah dicabut atau hilang PneumoVaxEver Kategorikal Status pernah menerima vaksin <i>pneumonia</i> TetanusLast10Tdap Kategorikal Status vaksin tetanus dalam 10 tahun terakhir HighRiskLastYear Kategorikal Indikator perilaku berisiko dalam 1 tahun terakhir HeightInMeters Float Tinggi badan responden dalam meter
Detail-detail langkah pre-processing	Tahapan Pre-Processing A. Diagram Alur <pre> graph TD A[Indicators of Heart Disease] --> B[EDA] subgraph EDA_Box [EDA] B1[Cek Tipe Data] B2[Distribusi Fitur & target] B3[Cek Missing Value] B4[Cek Outlier] B5[Cek Imbalance] B6[Korelasi Antar Fitur] end B --> C[Preprocessing] subgraph Preprocessing_Box [Preprocessing] subgraph Data_Cleaning [Data Cleaning] C1[Handling Missing Value] C2[Handling Outlier] C3[Duplikasi] end subgraph Feature_Engineering [Feature Engineering] C4[Feature Scaling] C5[Feature Selection] C6[Encoding] end end C --> D[Split Data 80/20] D --> E[SMOTE] E --> F[EDA Post-Processing] F --> G[Modeling] subgraph Modeling_Box [Modeling] G1[Logistic Regression] G2[Random Forest] G3[XGBoost] end G --> H[Evaluation and Compare Model] H --> I[Insight & visualisasi] </pre>

Gambar 1. Diagram Alur

	Dalam tahapan preprocessing dilakukan proses meliputi data <i>cleaning</i> dan <i>feature engineering</i>, berikut adalah rincian setiap tahapan <i>preprocessing</i> yang dilakukan : 1. Penghapusan <i>Missing Value</i> Pada Variabel Target Langkah pertama yang dilakukan adalah memastikan variabel target <i>GeneralHealth</i> tidak mengandung missing value, setelah dilakukan pengecekan terdapat 1198 baris missing value pada variabel target. Baris yang terindikasi missing value pada variabel target dihapus dari dataset menggunakan drop.na, hal ini dilakukan karena keberadaan missing value pada target akan menyebabkan model tidak dapat belajar secara benar, dan label yang hilang tidak bisa diimputasi karena justru merupakan nilai yang ingin diprediksi. 2. Penanganan Duplikat Pada dataset ditemukan data duplikat sejumlah 351, selanjutnya data yang duplikat akan dihapus menggunakan <code>df.drop.duplicates()</code>. 3. Split Data Sebelum proses imputasi dan transformasi fitur dilakukan, dataset terlebih dahulu dibagi menjadi data train dan data test dengan rasio 80:20 menggunakan library <i>scikit-learn</i>, parameter <code>test_size=0.2</code> digunakan untuk mengalokasikan 20% data sebagai data uji, <code>random_state=42</code> untuk memastikan hasil pembagian dapat direproduksi, serta <code>stratify=y</code> untuk menjaga proporsi tiap kelas pada variabel target tetap seimbang. Proses pembagian dilakukan sebelum imputasi dan scaling guna mencegah terjadinya data leakage, yaitu masuknya informasi dari data uji ke proses pelatihan model. 4. Imputasi Missing Value Pada Fitur a. Numerik Fitur-fitur seperti <i>BMI</i>, <i>SleepHours</i>, <i>PhysicalHealthDays</i>, <i>MentalHealthDays</i>, <i>HeightInMeters</i>, dan <i>WeightInKilograms</i>/Fitur numerik diimputasi menggunakan strategi median. Median dipilih sebagai pengganti mean karena lebih robust terhadap outlier b. Kategorik Pada fitur kategorikal data yang memiliki missing value diimputasi menggunakan '<i>Unknow</i>'. Hal ini dipilih karena nilai yang hilang pada variabel kategorikal tidak dapat dengan mudah diganti dengan nilai yang paling sering muncul atau modus tanpa risiko menimbulkan bias. 5. Encoding a. Binary encoding Fitur biner seperti <i>PhysicalActivities</i>, <i>ChestScan</i>, <i>AlcoholDrinkers</i>, <i>HIVTesting</i>, <i>FluVaxLast12</i>, <i>PneumoVaxEver</i>, <i>DifficultyWalking</i>, dan <i>HighRiskLastYear</i> dikonversi menggunakan pemetaan manual, yaitu nilai Yes menjadi 1, No menjadi 0, dan Unknown menjadi -1. Penggunaan nilai -1 pada kategori Unknown bertujuan agar model dapat membedakan antara jawaban negatif dan data yang tidak diketahui. Selain itu, fitur Sex juga dikonversi secara numerik dengan nilai Female sebagai 0 dan Male sebagai 1. b. One-hot encoding Fitur nominal tanpa urutan alami, seperti <i>State</i>, <i>RaceEthnicityCategory</i>, dan <i>TetanusLast10Tdap</i>, diencoding menggunakan metode One-Hot Encoding (OHE). Metode ini mengubah setiap kategori menjadi kolom biner baru. Parameter <code>drop='first'</code> digunakan untuk menghindari multikolinearitas,
--	--

	sedangkan <code>handle_unknown='ignore'</code> memungkinkan model menangani kategori baru pada data uji. Proses fitting dilakukan pada data train, kemudian diterapkan pada data latih dan data uji c. Ordinal encoding Fitur ordinal seperti <i>SmokerStatus</i>, <i>ECigaretteUsage</i>, <i>LastCheckupTime</i>, <i>RemovedTeeth</i>, dan <i>AgeCategory</i> diencoding menggunakan <i>OrdinalEncoder</i> dengan urutan kategori yang ditentukan secara eksplisit agar nilai numerik mencerminkan hirarki data. Untuk menangani kategori yang tidak dikenali pada data uji, digunakan parameter <code>handle_unknown='use_encoded_value'</code> dengan <code>unknown_value=-1</code> sehingga proses transformasi tetap dapat berjalan tanpa error. d. Encoding variabel target Variabel target <i>GeneralHealth</i> diencoding secara ordinal menggunakan <i>OrdinalEncoder</i> dengan urutan Poor (0), Fair (1), Good (2), Very Good (3), dan Excellent (4). Penggunaan encoding ordinal dilakukan agar model dapat memahami hubungan urutan antar kelas tingkat kesehatan. 6. Transformasi Fitur Numerik a. Log transformation untuk fitur skewed Fitur <i>PhysicalHealthDays</i> dan <i>MentalHealthDays</i> yang memiliki distribusi miring ke kanan ditransformasi menggunakan fungsi <code>log1p</code>. Transformasi ini dipilih karena aman untuk nilai nol serta mampu mengurangi kemiringan distribusi sehingga data menjadi lebih mendekati distribusi normal dan lebih sesuai untuk proses pemodelan machine learning. b. Standart Scaler Seluruh fitur numerik kontinu, yaitu <i>SleepHours</i>, <i>HeightInMeters</i>, <i>WeightInKilograms</i>, <i>BMI</i>, <i>PhysicalHealthDays</i>, dan <i>MentalHealthDays</i>, diskalakan menggunakan <i>StandardScaler</i> agar memiliki rata-rata 0 dan standar deviasi 1. Proses fitting dilakukan pada data latih, kemudian transformasi diterapkan pada data latih dan data uji untuk mencegah data <i>leakage</i>. Visualisasi distribusi sebelum dan sesudah scaling digunakan untuk memverifikasi hasil transformasi. 7. Validasi Akhir Pada tahapan ini setelah seluruh proses preprocessing selesai, dilakukan pengecekan akhir untuk memastikan tidak ada lagi missing value pada seluruh kolom data train.
--	---

Kemajuan Pengerjaan

Teknik yang digunakan	<i>Tuliskan teknik/algoritma yang sedang digunakan dalam proyek, misal: MLP / RNN / Ensemble Stacking, dst.</i> Pada proyek "Klasifikasi Status Kesehatan Berdasarkan Faktor Gaya Hidup Menggunakan Metode Ensemble Learning", digunakan pendekatan supervised machine learning untuk melakukan klasifikasi status kesehatan individu berdasarkan berbagai faktor gaya hidup dan indikator kesehatan. Teknik yang digunakan terdiri atas satu model baseline dan dua model ensemble learning untuk membandingkan performa dalam melakukan prediksi kelas status kesehatan. 1. Logistic Regression
-----------------------	---

	Logistic Regression merupakan algoritma supervised learning yang digunakan untuk melakukan klasifikasi dengan memodelkan hubungan antara variabel independen terhadap variabel target melalui pendekatan probabilitas. Model ini banyak digunakan pada bidang kesehatan untuk membantu proses prediksi kondisi individu berdasarkan berbagai indikator kesehatan dan karakteristik populasi (Clark et al., 2021). 2. Random Forest Random Forest merupakan algoritma ensemble learning berbasis metode bagging (Bootstrap Aggregating) yang bekerja dengan membangun sejumlah decision tree secara independen kemudian menggabungkan hasil prediksi seluruh pohon keputusan untuk menghasilkan prediksi akhir. Pendekatan ini memungkinkan model menangkap hubungan non-linear serta interaksi kompleks antara variabel yang umum ditemukan pada data kesehatan berbasis faktor gaya hidup (Hoekstra et al., 2023). 3. XGBoost XGBoost (Extreme Gradient Boosting) digunakan pada penelitian ini sebagai salah satu model klasifikasi untuk membandingkan performa prediksi status kesehatan individu berdasarkan faktor gaya hidup dan indikator kesehatan yang digunakan dalam penelitian. Penggunaan pendekatan machine learning dalam bidang kesehatan menunjukkan potensi dalam membantu proses prediksi kondisi individu berdasarkan karakteristik kesehatan dan data yang dimiliki sehingga dapat mendukung proses analisis kesehatan berbasis data (Yudhana et al., 2026). Pada penelitian ini, XGBoost digunakan sebagai bagian dari pendekatan ensemble learning untuk mengevaluasi kemampuan model dalam melakukan klasifikasi status kesehatan.																																														
Nilai metrik terakhir	1. <i>Logistic Regression</i> <i>Tabel 2 . Hasil Evaluasi Logistic Regression</i> <table><tr><th><i>Metrik</i></th><th><i>Nilai</i></th></tr><tr><td><i>Accuracy</i></td><td><i>0.44</i></td></tr><tr><td><i>Precision (Weighted Avg)</i></td><td><i>0.44</i></td></tr><tr><td><i>Recall (Weighted Avg)</i></td><td><i>0.44</i></td></tr><tr><td><i>F1-Score (Weighted Avg)</i></td><td><i>0.42</i></td></tr><tr><td><i>Precision (Macro Avg)</i></td><td><i>0.45</i></td></tr><tr><td><i>Recall (Macro Avg)</i></td><td><i>0.37</i></td></tr><tr><td><i>F1-Score (Macro Avg)</i></td><td><i>0.38</i></td></tr></table> <i>Tabel 3. Performa Setiap Kelas</i> <table><tr><th><i>Kelas Status Kesehatan</i></th><th><i>Precision</i></th><th><i>Recall</i></th><th><i>F1-Score</i></th><th><i>Support</i></th></tr><tr><td><i>Poor (0)</i></td><td><i>0.52</i></td><td><i>0.30</i></td><td><i>0.38</i></td><td><i>3948</i></td></tr><tr><td><i>Fair (1)</i></td><td><i>0.44</i></td><td><i>0.30</i></td><td><i>0.36</i></td><td><i>12054</i></td></tr><tr><td><i>Good (2)</i></td><td><i>0.43</i></td><td><i>0.48</i></td><td><i>0.45</i></td><td><i>28705</i></td></tr><tr><td><i>Very Good (3)</i></td><td><i>0.45</i></td><td><i>0.65</i></td><td><i>0.53</i></td><td><i>29653</i></td></tr><tr><td><i>Excellent (4)</i></td><td><i>0.41</i></td><td><i>0.10</i></td><td><i>0.17</i></td><td><i>14357</i></td></tr></table>	<i>Metrik</i>	<i>Nilai</i>	<i>Accuracy</i>	<i>0.44</i>	<i>Precision (Weighted Avg)</i>	<i>0.44</i>	<i>Recall (Weighted Avg)</i>	<i>0.44</i>	<i>F1-Score (Weighted Avg)</i>	<i>0.42</i>	<i>Precision (Macro Avg)</i>	<i>0.45</i>	<i>Recall (Macro Avg)</i>	<i>0.37</i>	<i>F1-Score (Macro Avg)</i>	<i>0.38</i>	<i>Kelas Status Kesehatan</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>	<i>Poor (0)</i>	<i>0.52</i>	<i>0.30</i>	<i>0.38</i>	<i>3948</i>	<i>Fair (1)</i>	<i>0.44</i>	<i>0.30</i>	<i>0.36</i>	<i>12054</i>	<i>Good (2)</i>	<i>0.43</i>	<i>0.48</i>	<i>0.45</i>	<i>28705</i>	<i>Very Good (3)</i>	<i>0.45</i>	<i>0.65</i>	<i>0.53</i>	<i>29653</i>	<i>Excellent (4)</i>	<i>0.41</i>	<i>0.10</i>	<i>0.17</i>	<i>14357</i>
<i>Metrik</i>	<i>Nilai</i>																																														
<i>Accuracy</i>	<i>0.44</i>																																														
<i>Precision (Weighted Avg)</i>	<i>0.44</i>																																														
<i>Recall (Weighted Avg)</i>	<i>0.44</i>																																														
<i>F1-Score (Weighted Avg)</i>	<i>0.42</i>																																														
<i>Precision (Macro Avg)</i>	<i>0.45</i>																																														
<i>Recall (Macro Avg)</i>	<i>0.37</i>																																														
<i>F1-Score (Macro Avg)</i>	<i>0.38</i>																																														
<i>Kelas Status Kesehatan</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>																																											
<i>Poor (0)</i>	<i>0.52</i>	<i>0.30</i>	<i>0.38</i>	<i>3948</i>																																											
<i>Fair (1)</i>	<i>0.44</i>	<i>0.30</i>	<i>0.36</i>	<i>12054</i>																																											
<i>Good (2)</i>	<i>0.43</i>	<i>0.48</i>	<i>0.45</i>	<i>28705</i>																																											
<i>Very Good (3)</i>	<i>0.45</i>	<i>0.65</i>	<i>0.53</i>	<i>29653</i>																																											
<i>Excellent (4)</i>	<i>0.41</i>	<i>0.10</i>	<i>0.17</i>	<i>14357</i>																																											

Model Logistic Regression memperoleh nilai *accuracy* sebesar 44% dengan *weighted F1-score* sebesar 0.42. Performa terbaik diperoleh pada kelas *Very Good* (kelas 3) dengan nilai *F1-score* sebesar 0.53, sedangkan performa terendah terdapat pada kelas *Excellent* (kelas 4) dengan *F1-score* sebesar 0.17. Hasil ini menunjukkan bahwa Logistic Regression cukup mampu digunakan sebagai baseline model, namun masih memiliki keterbatasan dalam membedakan beberapa kategori status kesehatan sehingga diperlukan perbandingan dengan metode *ensemble learning* seperti Random Forest dan XGBoost.

2. Random Forest

Tabel 4. Hasil Evaluasi Random Forest

<i>Metrik</i>	<i>Nilai</i>
<i>Accuracy</i>	0.45
<i>Precision (Weighted Avg)</i>	0.44
<i>Recall (Weighted Avg)</i>	0.45
<i>F1-Score (Weighted Avg)</i>	0.43
<i>Precision (Macro Avg)</i>	0.45
<i>Recall (Macro Avg)</i>	0.39
<i>F1-Score (Macro Avg)</i>	0.40

Random Forest memperoleh *accuracy* sebesar 45% dengan *weighted F1-Score* 0.43. Nilai ini menunjukkan bahwa model cukup mampu melakukan klasifikasi pada seluruh kelas status kesehatan secara umum. Selain itu, nilai marco *average* yang lebih rendah dibanding *weighted average* menunjukkan bahwa performa model pada tiap kelas belum sepenuhnya merata, terutama pada kelas dengan jumlah data lebih sedikit.

Tabel 5. Performa Setiap Kelas


<i>Kelas Status Kesehatan</i>	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Support</i>
<i>Poor (0)</i>	0.53	0.36	0.43	3948
<i>Fair (1)</i>	0.43	0.31	0.36	12054
<i>Good (2)</i>	0.43	0.52	0.47	28705
<i>Very Good (3)</i>	0.46	0.57	0.51	29653
<i>Excellent (4)</i>	0.42	0.17	0.24	14357

Hasil pada Tabel 5 menunjukkan bahwa Random Forest cukup baik dalam mengenali pola hubungan antara faktor gaya hidup dan status kesehatan. Performa terbaik terdapat pada kelas *Very Good* (3) dengan *F1-score* 0.51, sedangkan kelas *Excellent* (4) masih sulit diprediksi dengan *F1-score* 0.24. Secara umum, penggunaan banyak *decision tree* membuat *Random Forest* lebih stabil dalam menangkap pola data kesehatan yang kompleks.

3. XGBoost

Tabel 6. Hasil Evaluasi Model XGBoost

<i>Metrik</i>	<i>Nilai</i>
<i>Accuracy</i>	0.46
<i>Precision (Weighted Avg)</i>	0.46
<i>Recall (Weighted Avg)</i>	0.46




Gambar 2. *Confusion Matrix* Logistic Regression

Visualisasi evaluasi model *Logistic Regression* menggunakan *Confusion Matrix* untuk melihat penyebaran prediksi pada setiap kelas:

- Prediksi Akurat (Diagonal Utama): Model paling sukses memprediksi data pada kelas 3 (*Very Good*) dengan 19.293 data benar, diikuti kelas 2 (*Good*) sebanyak 13.762 data benar.
- Misklasifikasi: Terjadi banyak *misclassification* yang menumpuk di sekitar kelas 2 dan 3. Sebagai contoh, pada kelas 4 (*Excellent*), mayoritas data justru salah diprediksi masuk ke kelas 3 (9.822 data) dan kelas 2 (2.866 data), sehingga menyisakan hanya 1.486 data yang terprediksi dengan benar. Hal inilah yang menyebabkan nilai *recall* dan *F1-score* pada kelas ekstrem (seperti *Excellent*) menjadi sangat rendah.

2. *Random Forest*




Gambar 3. *Confusion Matrix* Random Forest

Visualisasi pada Gambar 3 menunjukkan karakteristik prediksi sebagai berikut:

- Prediksi Akurat (Diagonal Utama): Mirip dengan model baseline, akurasi prediksi tertinggi terkonsentrasi pada kelas 3 (*Very Good*) dengan 16.996 data benar dan kelas 2 (*Good*) sebanyak 14.931 data benar.
- Perbaikan pada Kelas Minoritas: Jika dibandingkan dengan Logistic Regression, Random Forest menunjukkan peningkatan kemampuan dalam mengenali kelas ekstrem. Pada kelas 4 (*Excellent*), jumlah prediksi yang benar meningkat menjadi 2.430 data. Meskipun begitu, tingkat klasifikasi masih cukup tinggi karena sebagian besar data *Excellent* tetap terkejar dan salah diprediksi masuk ke kelas 3 (8.121 data) serta kelas 2 (3.586 data).

3. *XGBoost*



Gambar 4. *Confusion Matrix* XGBoost

Hasil yang dapat kita lihat dari Gambar 4 adalah sebagai berikut:

- Prediksi Akurat (Diagonal Utama): Model ini mempunyai performa tertinggi pada kelas 3 (*Very Good*) dengan berhasil menebak 18.371 data secara tepat, diikuti oleh kelas 2 (*Good*) sebanyak 14.558 data benar. Selain itu, kemampuan memprediksi kelas 0 (*Poor*) juga meningkat paling baik dibandingkan model lain, yaitu mencapai 1.617 data benar.
- Walaupun menjadi model dengan akurasi keseluruhan terbaik, XGBoost masih terhambat oleh masalah salah prediksi pada kelas ekstrem. Pada kelas 4 (*Excellent*), hanya 2.350 data yang berhasil ditebak dengan benar, sementara sebagian besar datanya masih bias dan meleset ke kelas 3 (8.764 data) serta kelas 2 (3.041 data).

Temuan

Berdasarkan proses pelatihan, ketiga model menghasilkan akurasi yang masih rendah di kisaran 44%–45% akibat adanya masalah ketidakseimbangan data (*class imbalance*). Model cenderung bias karena hanya akurat dalam memprediksi kelas dengan jumlah data banyak seperti *Very Good*, tetapi sangat lemah ketika memprediksi kelas yang datanya sedikit seperti *Excellent*. Oleh karena itu, langkah tindak lanjut yang sangat disarankan adalah menerapkan teknik penanganan ketidakseimbangan data menggunakan SMOTE (sesuai dengan rencana pada diagram alur) serta melakukan *hyperparameter tuning* (seperti *Grid Search* atau *Random Search*) agar model dapat memprediksi seluruh kelas secara lebih adil, optimal, dan akurat.