

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024C
Ketua	Kevin Foreman Hutahaeon (24031554095)
Anggota 1	Kartika Nur Savira (24031554049)
Anggota 2	Diyanti Pratiwi (24031554016)
URL Github	https://github.com/Kartika-Nur-Savira/ML_Project9/tree/main

Informasi Umum Proyek

Judul	Deteksi Dini Kanker Payudara Berdasarkan Fitur Geometri dan Karakteristik Seluler Tumor Menggunakan Ensemble Machine Learning
Topik	Big Data Kesehatan
Pilihan Rumusan Masalah	2.6 Pemanfaatan AI dan Big Data Kesehatan
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	Kanker payudara merupakan salah satu jenis kanker paling umum pada perempuan dan menjadi penyebab kematian yang signifikan di dunia. Menurut <i>World Health Organization (WHO)</i>, terdapat sekitar 2,3 juta kasus baru kanker payudara dan sekitar 670.000 kematian secara global pada tahun 2022. Tingginya jumlah kasus tersebut menyebabkan deteksi dini menjadi sangat penting untuk meningkatkan peluang kesembuhan pasien. Namun, proses diagnosis kanker payudara masih membutuhkan analisis medis yang kompleks dan waktu yang cukup lama. Oleh karena itu, pemanfaatan <i>Artificial Intelligence (AI)</i> dan <i>Machine Learning</i> dapat menjadi solusi untuk membantu proses klasifikasi kanker payudara secara lebih cepat dan akurat berdasarkan karakteristik tumor dan sel kanker (WHO, 2022). Meskipun demikian, implementasi <i>machine learning</i> pada klasifikasi kanker payudara masih memiliki tantangan karena data medis terdiri dari banyak fitur geometris, tekstur, dan karakteristik biologis yang kompleks. Selain itu, kesalahan klasifikasi terutama <i>false negative</i> pada tumor ganas dapat menyebabkan keterlambatan penanganan pasien dan meningkatkan risiko kematian. Oleh sebab itu, diperlukan model <i>machine learning</i> dengan performa tinggi dan stabil agar dapat membantu proses deteksi dini kanker payudara secara optimal. Penelitian ini menggunakan pendekatan ensemble machine learning untuk melakukan klasifikasi kanker payudara berdasarkan fitur geometri tumor dan karakteristik biologis seluler guna memperoleh model terbaik dalam mendukung implementasi AI pada bidang kesehatan.
Tujuan penelitian (Objectives)	Tuliskan tahapan-tahapan, atau target penyelesaian 1. Melakukan proses data understanding dan exploratory data analysis (EDA) pada dataset kanker payudara untuk memahami karakteristik fitur geometri tumor dan karakteristik biologis seluler. 2. Melakukan tahap data preprocessing meliputi pengecekan missing value, duplikasi data, encoding label, feature scaling, dan pembagian data latih serta data uji untuk mempersiapkan data sebelum proses pemodelan.

	3. Membangun model klasifikasi kanker payudara menggunakan beberapa algoritma <i>Machine Learning</i> seperti <i>Logistic Regression</i>, <i>Random Forest</i>, dan <i>XGBoost</i>. 4. Membandingkan performa masing-masing algoritma menggunakan metrik evaluasi seperti Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix untuk memperoleh model terbaik. 5. Menganalisis fitur-fitur yang paling berpengaruh terhadap klasifikasi kanker payudara berdasarkan hasil evaluasi dan <i>feature importance</i> dari model terbaik. 6. Menghasilkan model klasifikasi kanker payudara berbasis <i>ensemble machine learning</i> yang dapat mendukung implementasi <i>Artificial Intelligence (AI)</i> pada bidang kesehatan, khususnya untuk membantu deteksi dini kanker payudara.
Referensi penelitian	1. https://doi.org/10.1109/ICCCNT49239.2020.9225451 2. https://doi.org/10.1016/j.bspc.2021.103279 3. https://doi.org/10.1016/j.compbimed.2021.104931 4. https://doi.org/10.3233/JIFS-219176 5. https://doi.org/10.1016/j.irbm.2020.05.005

Informasi Detail Dataset


Sumber dataset	https://www.kaggle.com/datasets/sharmajicoder/breast-cancer-dataset																																																																																																				
Deskripsi awal fitur dataset	Dataset yang digunakan terdiri dari 500.000 sampel dengan 40 fitur prediktor dan satu variabel target yaitu diagnosis. Variabel target memiliki dua kelas, yaitu <i>Benign</i> dan <i>Malignant</i> , sehingga termasuk dalam tugas <i>binary classification</i> . Dataset disimpan dalam format CSV dan digunakan untuk membangun model klasifikasi guna memprediksi diagnosis kanker berdasarkan fitur-fitur yang tersedia.																																																																																																				
	<table><tr><th colspan="4">Tabel 1. Variabel Penelitian</th></tr><tr><th>No</th><th>Variable Name</th><th>Data Type</th><th>Description</th></tr><tr><td>1</td><td><i>radius_mean</i></td><td>Float</td><td>Mean radius of the tumor</td></tr><tr><td>2</td><td><i>texture_mean</i></td><td>Float</td><td>Average texture variation</td></tr><tr><td>3</td><td><i>perimeter_mean</i></td><td>Float</td><td>Mean perimeter of tumor cells</td></tr><tr><td>4</td><td><i>area_mean</i></td><td>Float</td><td>Mean tumor area</td></tr><tr><td>5</td><td><i>smoothness_mean</i></td><td>Float</td><td>Tumor boundary smoothness</td></tr><tr><td>6</td><td><i>compactness_mean</i></td><td>Float</td><td>Compactness of tumor shape</td></tr><tr><td>7</td><td><i>concavity_mean</i></td><td>Float</td><td>Degree of concave portions</td></tr><tr><td>8</td><td><i>concave_points_mean</i></td><td>Float</td><td>Number of concave points</td></tr><tr><td>9</td><td><i>symmetry_mean</i></td><td>Float</td><td>Symmetry of tumor structure</td></tr><tr><td>10</td><td><i>fractal_dimension_mean</i></td><td>Float</td><td>Complexity of tumor boundary</td></tr><tr><td>11</td><td><i>radius_se</i></td><td>Float</td><td>Standard error of radius</td></tr><tr><td>12</td><td><i>texture_se</i></td><td>Float</td><td>Standard error of texture</td></tr><tr><td>13</td><td><i>perimeter_se</i></td><td>Float</td><td>Standard error of perimeter</td></tr><tr><td>14</td><td><i>area_se</i></td><td>Float</td><td>Standard error of area</td></tr><tr><td>15</td><td><i>smoothness_se</i></td><td>Float</td><td>Standard error of smoothness</td></tr><tr><td>16</td><td><i>compactness_se</i></td><td>Float</td><td>Standard error of compactness</td></tr><tr><td>17</td><td><i>concavity_se</i></td><td>Float</td><td>Standard error of concavity</td></tr><tr><td>18</td><td><i>concave_points_se</i></td><td>Float</td><td>Standard error of concave points</td></tr><tr><td>19</td><td><i>symmetry_se</i></td><td>Float</td><td>Standard error of symmetry</td></tr><tr><td>20</td><td><i>fractal_dimension_se</i></td><td>Float</td><td>Standard error of fractal dimension</td></tr><tr><td>21</td><td><i>radius_worst</i></td><td>Float</td><td>Largest radius measurement</td></tr><tr><td>22</td><td><i>texture_worst</i></td><td>Float</td><td>Largest texture measurement</td></tr><tr><td>23</td><td><i>perimeter_worst</i></td><td>Float</td><td>Largest perimeter measurement</td></tr></table>	Tabel 1. Variabel Penelitian				No	Variable Name	Data Type	Description	1	<i>radius_mean</i>	Float	Mean radius of the tumor	2	<i>texture_mean</i>	Float	Average texture variation	3	<i>perimeter_mean</i>	Float	Mean perimeter of tumor cells	4	<i>area_mean</i>	Float	Mean tumor area	5	<i>smoothness_mean</i>	Float	Tumor boundary smoothness	6	<i>compactness_mean</i>	Float	Compactness of tumor shape	7	<i>concavity_mean</i>	Float	Degree of concave portions	8	<i>concave_points_mean</i>	Float	Number of concave points	9	<i>symmetry_mean</i>	Float	Symmetry of tumor structure	10	<i>fractal_dimension_mean</i>	Float	Complexity of tumor boundary	11	<i>radius_se</i>	Float	Standard error of radius	12	<i>texture_se</i>	Float	Standard error of texture	13	<i>perimeter_se</i>	Float	Standard error of perimeter	14	<i>area_se</i>	Float	Standard error of area	15	<i>smoothness_se</i>	Float	Standard error of smoothness	16	<i>compactness_se</i>	Float	Standard error of compactness	17	<i>concavity_se</i>	Float	Standard error of concavity	18	<i>concave_points_se</i>	Float	Standard error of concave points	19	<i>symmetry_se</i>	Float	Standard error of symmetry	20	<i>fractal_dimension_se</i>	Float	Standard error of fractal dimension	21	<i>radius_worst</i>	Float	Largest radius measurement	22	<i>texture_worst</i>	Float	Largest texture measurement	23	<i>perimeter_worst</i>	Float	Largest perimeter measurement
	Tabel 1. Variabel Penelitian																																																																																																				
	No	Variable Name	Data Type	Description																																																																																																	
	1	<i>radius_mean</i>	Float	Mean radius of the tumor																																																																																																	
	2	<i>texture_mean</i>	Float	Average texture variation																																																																																																	
	3	<i>perimeter_mean</i>	Float	Mean perimeter of tumor cells																																																																																																	
	4	<i>area_mean</i>	Float	Mean tumor area																																																																																																	
	5	<i>smoothness_mean</i>	Float	Tumor boundary smoothness																																																																																																	
	6	<i>compactness_mean</i>	Float	Compactness of tumor shape																																																																																																	
	7	<i>concavity_mean</i>	Float	Degree of concave portions																																																																																																	
	8	<i>concave_points_mean</i>	Float	Number of concave points																																																																																																	
	9	<i>symmetry_mean</i>	Float	Symmetry of tumor structure																																																																																																	
	10	<i>fractal_dimension_mean</i>	Float	Complexity of tumor boundary																																																																																																	
	11	<i>radius_se</i>	Float	Standard error of radius																																																																																																	
	12	<i>texture_se</i>	Float	Standard error of texture																																																																																																	
	13	<i>perimeter_se</i>	Float	Standard error of perimeter																																																																																																	
	14	<i>area_se</i>	Float	Standard error of area																																																																																																	
	15	<i>smoothness_se</i>	Float	Standard error of smoothness																																																																																																	
	16	<i>compactness_se</i>	Float	Standard error of compactness																																																																																																	
	17	<i>concavity_se</i>	Float	Standard error of concavity																																																																																																	
	18	<i>concave_points_se</i>	Float	Standard error of concave points																																																																																																	
	19	<i>symmetry_se</i>	Float	Standard error of symmetry																																																																																																	
	20	<i>fractal_dimension_se</i>	Float	Standard error of fractal dimension																																																																																																	
	21	<i>radius_worst</i>	Float	Largest radius measurement																																																																																																	
22	<i>texture_worst</i>	Float	Largest texture measurement																																																																																																		
23	<i>perimeter_worst</i>	Float	Largest perimeter measurement																																																																																																		

	24 area_worst Float Largest tumor area observed 25 smoothness_worst Float Worst smoothness value 26 compactness_worst Float Worst compactness value 27 concavity_worst Float Worst concavity value 28 concave_points_worst Float Worst concave points value 29 symmetry_worst Float Worst symmetry measurement 30 fractal_dimension_worst Float Worst fractal dimension 31 cell_density Float Density of cells in tumor tissue 32 nucleus_size Float Average size of cell nuclei 33 nucleus_texture Float Variation in nucleus texture 34 mitosis_rate Float Rate of cell division 35 tumor_border_irregularity Float Irregularity of tumor borders 36 chromatin_density Float Chromatin concentration in nucleus 37 cell_variation Float Variation in cell sizes 38 nuclear_variation Float Variation in nucleus shapes 39 cytoplasm_ratio Float Cytoplasm to nucleus ratio 40 cell_clump_thickness Float Thickness of cell clusters 41 diagnosis Object / Categoric Tumor diagnosis result (Benign / Malignant)																																																																																																																								
Aspek khusus dari dataset	1. Apakah datanya sparse? Berdasarkan hasil pengecekan jumlah missing value pada data untuk semua kolom adalah 0, atau persentase <i>sparsity</i> dalam konteks kelengkapan data adalah 0%. Data didominasi oleh tipe data float yang berisi angka desimal. 2. Bagaimana ringkasan statistik deskriptifnya? Tabel 2. Ringkasan statistik deskriptif <table><tr><th>Variabel</th><th>Mean</th><th>Std</th><th>Min</th><th>Max</th><th>Skewness</th></tr><tr><td>radius_mean</td><td>13.998</td><td>3.003</td><td>0.168</td><td>28.689</td><td>0.004</td></tr><tr><td>texture_mean</td><td>19.998</td><td>5.001</td><td>0.024</td><td>43.231</td><td>-0.004</td></tr><tr><td>perimeter_mean</td><td>83.975</td><td>19.362</td><td>0.909</td><td>179.970</td><td>0.156</td></tr><tr><td>area_mean</td><td>643.922</td><td>267.268</td><td>0.088</td><td>2585.669</td><td>0.634</td></tr><tr><td>smoothness_mean</td><td>-0.000</td><td>0.998</td><td>-4.872</td><td>4.814</td><td>-0.001</td></tr><tr><td>compactness_mean</td><td>0.000</td><td>1.001</td><td>-4.574</td><td>5.220</td><td>0.001</td></tr><tr><td>concavity_mean</td><td>0.000</td><td>0.999</td><td>-4.573</td><td>5.022</td><td>-0.003</td></tr><tr><td>concave_points_mean</td><td>0.001</td><td>1.000</td><td>-4.677</td><td>4.655</td><td>-0.005</td></tr><tr><td>symmetry_mean</td><td>0.001</td><td>1.000</td><td>-4.482</td><td>4.611</td><td>-0.000</td></tr><tr><td>fractal_dimension_mean</td><td>0.001</td><td>1.000</td><td>-4.625</td><td>4.575</td><td>-0.000</td></tr><tr><td>radius_se</td><td>-0.000</td><td>1.001</td><td>-4.980</td><td>4.719</td><td>0.001</td></tr><tr><td>texture_se</td><td>0.003</td><td>1.001</td><td>-4.717</td><td>4.798</td><td>0.007</td></tr><tr><td>perimeter_se</td><td>-0.002</td><td>1.000</td><td>-4.829</td><td>5.076</td><td>0.000</td></tr><tr><td>area_se</td><td>0.002</td><td>0.999</td><td>-4.535</td><td>4.732</td><td>-0.004</td></tr><tr><td>smoothness_se</td><td>-0.000</td><td>1.001</td><td>-5.306</td><td>4.920</td><td>0.004</td></tr><tr><td>compactness_se</td><td>0.001</td><td>1.000</td><td>-4.631</td><td>4.738</td><td>0.000</td></tr><tr><td>concavity_se</td><td>0.001</td><td>1.001</td><td>-4.317</td><td>4.786</td><td>-0.004</td></tr><tr><td>concave_points_se</td><td>0.000</td><td>1.000</td><td>-4.581</td><td>4.679</td><td>-0.001</td></tr><tr><td>symmetry_se</td><td>0.002</td><td>1.000</td><td>-4.480</td><td>4.795</td><td>-0.000</td></tr></table>	Variabel	Mean	Std	Min	Max	Skewness	radius_mean	13.998	3.003	0.168	28.689	0.004	texture_mean	19.998	5.001	0.024	43.231	-0.004	perimeter_mean	83.975	19.362	0.909	179.970	0.156	area_mean	643.922	267.268	0.088	2585.669	0.634	smoothness_mean	-0.000	0.998	-4.872	4.814	-0.001	compactness_mean	0.000	1.001	-4.574	5.220	0.001	concavity_mean	0.000	0.999	-4.573	5.022	-0.003	concave_points_mean	0.001	1.000	-4.677	4.655	-0.005	symmetry_mean	0.001	1.000	-4.482	4.611	-0.000	fractal_dimension_mean	0.001	1.000	-4.625	4.575	-0.000	radius_se	-0.000	1.001	-4.980	4.719	0.001	texture_se	0.003	1.001	-4.717	4.798	0.007	perimeter_se	-0.002	1.000	-4.829	5.076	0.000	area_se	0.002	0.999	-4.535	4.732	-0.004	smoothness_se	-0.000	1.001	-5.306	4.920	0.004	compactness_se	0.001	1.000	-4.631	4.738	0.000	concavity_se	0.001	1.001	-4.317	4.786	-0.004	concave_points_se	0.000	1.000	-4.581	4.679	-0.001	symmetry_se	0.002	1.000	-4.480	4.795	-0.000
Variabel	Mean	Std	Min	Max	Skewness																																																																																																																				
radius_mean	13.998	3.003	0.168	28.689	0.004																																																																																																																				
texture_mean	19.998	5.001	0.024	43.231	-0.004																																																																																																																				
perimeter_mean	83.975	19.362	0.909	179.970	0.156																																																																																																																				
area_mean	643.922	267.268	0.088	2585.669	0.634																																																																																																																				
smoothness_mean	-0.000	0.998	-4.872	4.814	-0.001																																																																																																																				
compactness_mean	0.000	1.001	-4.574	5.220	0.001																																																																																																																				
concavity_mean	0.000	0.999	-4.573	5.022	-0.003																																																																																																																				
concave_points_mean	0.001	1.000	-4.677	4.655	-0.005																																																																																																																				
symmetry_mean	0.001	1.000	-4.482	4.611	-0.000																																																																																																																				
fractal_dimension_mean	0.001	1.000	-4.625	4.575	-0.000																																																																																																																				
radius_se	-0.000	1.001	-4.980	4.719	0.001																																																																																																																				
texture_se	0.003	1.001	-4.717	4.798	0.007																																																																																																																				
perimeter_se	-0.002	1.000	-4.829	5.076	0.000																																																																																																																				
area_se	0.002	0.999	-4.535	4.732	-0.004																																																																																																																				
smoothness_se	-0.000	1.001	-5.306	4.920	0.004																																																																																																																				
compactness_se	0.001	1.000	-4.631	4.738	0.000																																																																																																																				
concavity_se	0.001	1.001	-4.317	4.786	-0.004																																																																																																																				
concave_points_se	0.000	1.000	-4.581	4.679	-0.001																																																																																																																				
symmetry_se	0.002	1.000	-4.480	4.795	-0.000																																																																																																																				

fractal_dimension_se	-0.001	1.000	-4.513	4.739	-0.003
radius_worst	16.015	3.154	0.953	31.157	0.010
texture_worst	0.001	0.999	-4.672	4.984	-0.005
perimeter_worst	-0.003	0.999	-4.628	4.483	-0.001
area_worst	837.231	374.642	0.130	4010.403	0.821
smoothness_worst	0.001	0.999	-4.534	5.129	-0.001
compactness_worst	0.000	0.999	-4.394	4.577	0.000
concavity_worst	0.000	1.000	-4.622	5.034	-0.003
concave_points_worst	-0.001	1.000	-4.824	4.671	-0.001
symmetry_worst	-0.000	1.001	-4.812	4.358	-0.005
fractal_dimension_worst	-0.001	1.000	-4.381	4.315	-0.004
cell_density	49.984	14.987	0.001	122.558	0.005
nucleus_size	10.001	2.993	0.003	23.976	0.010
nucleus_texture	-0.001	1.002	-4.809	5.020	0.001
mitosis_rate	4.034	1.931	0.000	13.583	0.187
tumor_border_irregularity	0.500	0.198	0.000	1.398	0.072
chromatin_density	-0.002	0.999	-4.639	4.580	-0.003
cell_variation	0.000	1.000	-4.378	4.434	-0.003
nuclear_variation	0.001	1.000	-4.632	4.828	0.005
cytoplasm_ratio	0.001	0.999	-5.195	4.679	-0.002
cell_clump_thickness	-0.001	1.001	-5.119	4.913	0.003

Berdasarkan statistik deskriptif pada Tabel 2, sebagian besar variabel memiliki mean mendekati 0 dan standar deviasi sekitar 1 karena telah distandarisasi. Nilai skewness mayoritas juga mendekati 0 sehingga distribusi data cenderung simetris atau mendekati normal. Namun, beberapa variabel seperti 'are_mean' dan 'area_worst' menunjukkan skewness positif.


3. Apakah datanya imbalanced?



Gambar 1. Distribusi Kelas Target

Distribusi kelas target pada variabel diagnosis menunjukkan bahwa data didominasi oleh kelas benign (0) dengan sebaran sebanyak 62.241 (65.2%), sedangkan pada kelas malignant (1) jumlah data lebih sedikit sebanyak 34.759 (34.8%), dengan rasio antara keduanya yaitu 2:1. Kondisi ini menunjukkan adanya *class imbalance* ringan, karena jumlah data pada kelas benign lebih banyak dibandingkan kelas malignant.

4. Bagaimana outlier nya?




Gambar 2. Distribusi Outlier Pada Fitur

Pada visualisasi *boxplot* terlihat adanya *outlier* pada setiap variabel yang ditandai dengan adanya titik diluar *whisker*, *outlier* paling banyak muncul pada variabel *area_mean*, *area_worst*, *radius_mean*, dan *radius_worst*, terutama pada kelas *Malignant*, yang menunjukkan adanya tumor dengan ukuran jauh lebih besar dibanding data lainnya. Sementara itu, variabel lainnya memiliki penyebaran *outlier* yang relatif seimbang pada kedua kelas. *Outlier* pada fitur-fitur ini memiliki rentang 1700 hingga 8800 data outlier, namun *outlier* masih wajar karena perbedaan kondisi pada tiap pasien.

5. Apakah ada data yang terduplikat?

Berdasarkan hasil pengecekan duplikasi pada data untuk semua kolom adalah 0, artinya tidak terdapat baris data yang identik secara keseluruhan dalam dataset. Setiap sampel merupakan data yang unik sehingga tidak diperlukan proses penghapusan duplikat.


6. Sebarannya seperti apa?



Gambar 3. Distribusi Fitur dengan Separasi Kelas Tertinggi

Dari hasil eksplorasi distribusi seluruh fitur terlihat bahwa semua fitur berdistribusi normal, visualisasi berikut menampilkan lima fitur dengan separasi kelas tertinggi antara benign dan malignant, yaitu 'radius_mean', 'perimeter_mean', 'area_mean', 'radius_worst', dan area_worst. Berdasarkan visualisasi, kelas benign (0) cenderung memiliki nilai yang lebih rendah dan terpusat, sedangkan kelas malignant (1) memiliki nilai lebih tinggi dengan sebaran yang lebih lebar. Hal ini mengindikasikan bahwa tumor ganas secara umum memiliki ukuran radius, perimeter, dan area yang lebih besar dibandingkan tumor jinak.


7. Bagaimana korelasi antar fiturnya?



Gambar 4. Korelasi Antar Fitur


Berdasarkan heatmap korelasi antar fitur pada Gambar 4, terlihat bahwa sebagian besar fitur memiliki korelasi rendah satu sama lain (ditunjukkan dengan warna abu-abu). Namun terdapat beberapa pasang fitur dengan korelasi sangat tinggi (warna merah gelap), yaitu antara 'radius_mean', 'perimeter_mean', dan 'area_mean', serta antara 'radius_worst', 'perimeter_worst', dan 'area_worst'. Hal ini wajar karena ketiga fitur tersebut memang saling berkaitan semakin besar radius, maka perimeter dan area tumor juga akan ikut membesar.

8. Bagaimana korelasi fitur dengan target?

	 Gambar 5. Korelasi Fitur Dengan Target Berdasarkan hasil analisis pada Gambar 5, hanya lima fitur yang menunjukkan korelasi signifikan yaitu ‘area_worst’, ‘area_mean’, ‘radius_mean’, ‘radius_worst’, ‘perimeter_worst’, dan ‘perimeter_mean’. Kelima fitur ini merupakan fitur berbasis ukuran geometri tumor.

Rencana Metode

Teknik yang digunakan	<i>Logistic Regression (baseline)</i> <i>Random Forest (ensemble bagging)</i> <i>XGBoost / Gradient Boosting (ensemble boosting)</i>
Alasan pemilihan teknik/algoritma	Logistic Regression dipilih sebagai model baseline karena memiliki kompleksitas komputasi rendah sehingga efisien dijalankan pada dataset berskala besar dengan 500.000 observasi, model bersifat linear dan mudah untuk diinterpretasikan sehingga dapat dijadikan acuan minimum performa yang harus dilampaui oleh model ensemble. Random Forest dipilih karena merupakan metode ensemble berbasis bagging yang mampu menangani data tabular berukuran besar, dan random forest sendiri terbukti robust terhadap outlier sehingga mengurangi risiko overfitting. XGBoost dipilih karena merupakan metode boosting yang memiliki performa tinggi dalam klasifikasi, mampu mempelajari pola kompleks seperti pada dataset kami fitur geometri, tekstur dan karakteristik biologis sel yang saling berkaitan sehingga <i>XGBoost</i> digunakan untuk melihat pola datanya, <i>XGBoost</i> juga digunakan untuk memperbaiki kesalahan prediksi menggunakan <i>boosting</i> sehingga nanti memiliki performa yang stabil, serta sering memberikan hasil akurasi terbaik pada data medis dan tidak seimbang.
Langkah-langkah umum pengerjaan	<i>Tuliskan gambaran awal Anda menyelesaikan proses latih model tersebut.</i> <i>Metrik apa yang Anda gunakan?</i> 1. Diagram Alur



1. Memahami dan mengeksplorasi dataset melakukan pengecekan struktur data, missing value, cek outlier, cek imbalance, dan distribusi fitur.
2. Melakukan Preprocessing data cleaning (Handling outlier), serta melakukan feature *engineering* seleksi fitur dan scaling untuk menyamakan bobot data yang mungkin berbeda.
3. Membagi dataset menjadi data latih (80) dan data uji (20).
4. Melakukan EDA post processing untuk melihat distribusi data setelah dilakukan *preprocessing*.
5. Melatih tiga model: Logistic Regression, Random Forest, dan XGBoost / Gradient Boosting.
6. Melakukan evaluasi performa masing-masing model pada data uji.
7. Membandingkan hasil performa ketiga model.
Metrik Evaluasi yang Digunakan
Accuracy
Precision
Recall
F1-score
Confusion Matrix
8. Membuat insight dan visualisasi