

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024C
Ketua	Kevin Foreman Hutahaeen (24031554095)
Anggota 1	Kartika Nur Savira (24031554049)
Anggota 2	Diyanti Pratiwi (24031554016)
URL Github	https://github.com/Kartika-Nur-Savira/ML_Project9/tree/main

Informasi Umum Proyek

Judul	Klasifikasi Status Kesehatan Berdasarkan Faktor Gaya Hidup Menggunakan Metode <i>Ensemble Learning</i>
Topik	Big Data Kesehatan
Pilihan Rumusan Masalah	2.6 Pemanfaatan AI dan Big Data Kesehatan
Revisi?	Ya / Tidak

Deskripsi Rumusan masalah	Status kesehatan umum (<i>general health</i>) seseorang merupakan cerminan menyeluruh dari kondisi fisik, mental, gaya hidup yang dijalannya sehari-hari terbukti menjadi prediktor kuat terhadap kematian dini, kejadian penyakit, serta tingginya biaya pengobatan [1]. Indonesia sebagai negara dengan jumlah penduduk lebih dari 270 juta jiwa menghadapi tantangan besar dalam pemantauan status kesehatan masyarakat secara menyeluruh, terutama di wilayah-wilayah yang memiliki keterbatasan akses terhadap fasilitas pelayanan kesehatan. Kondisi ini menyebabkan banyak individu tidak memiliki rekam medis atau data riwayat penyakit yang lengkap, sehingga pendekatan prediksi yang bergantung pada data klinis menjadi sulit diterapkan secara luas. Peneliti sebelumnya menunjukkan bahwa faktor-faktor non-klinis seperti aktivitas fisik, status sosial ekonomi, dan perilaku kesehatan memiliki peran penting yang sangat signifikan terhadap status kesehatan, bahkan tanpa bergantung pada data riwayat penyakit [1], [3]. Temuan ini membuka peluang untuk mengembangkan model prediksi status kesehatan berbasis data yang mudah diperoleh tanpa prosedur medis, yang sangat relevan dengan Riset Kesehatan Dasar (Riset Kesehatan Dasar). Oleh karena itu, penelitian ini berfokus pada prediksi status kesehatan hanya berdasarkan informasi yang dapat diperoleh tanpa diagnosis medis menggunakan perbandingan algoritma <i>Logistic Regression</i>, <i>Random Forest</i>, dan <i>XGBoost</i> untuk mengklasifikasikan ‘<i>GeneralHealth</i>’. Jika terbukti efektif, pendekatan ini berpotensi diadaptasi ke dalam sistem pemantauan kesehatan masyarakat di Indonesia, membantu tenaga kesehatan dan pembuat kebijakan dalam mengidentifikasi masyarakat berisiko secara lebih cepat dan efisien.
Tujuan penelitian (Objectives)	Penelitian ini bertujuan untuk memberikan kontribusi bagi kemajuan sistem kesehatan Indonesia dan kesejahteraan masyarakat luas. Berikut tujuan penelitian secara menyeluruh : 1. Membangun model klasifikasi kesehatan umum yang akurat dan efisien sebagai bentuk dukungan terhadap program pemantauan kesehatan masyarakat dan

	pengecahan penyakit tidak menular yang menjadi prioritas Kementerian Kesehatan Republik Indonesia. - Membandingkan performa masing-masing algoritma menggunakan matrik evaluasi seperti <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i>, <i>F1-Score</i>, dan <i>Confusion Matrix</i> untuk memperoleh model terbaik. - Mengidentifikasi faktor faktor gaya hidup, kondisi fisik, dan sosiodemografi yang paling berpengaruh terhadap kesehatan umum seseorang menggunakan SHAP (<i>SHapley Additive exPlanations</i>, sehingga hasilnya dapat menjadi referensi bagi tenaga kesehatan dan pembuat kebijakan dalam merancang program intervensi kesehatan yang lebih tepat sasaran. - Menyediakan bukti ilmiah yang mendukung penerapan <i>Explainable Artificial Intelligence</i> (XAI) di bidang kesehatan Indonesia untuk membantu identifikasi kelompok masyarakat berisiko rendah hingga tinggi berdasarkan kondisi kesehatannya, khususnya di daerah yang memiliki keterbatasan tenaga ahli kesehatan, sehingga dapat mendukung upaya promotif dan preventif dalam menekan angka kesakitan.
Referensi penelitian	https://doi.org/10.1007/s11606-020-06438-1 https://doi.org/10.1016/j.ahjo.2026.100719 https://doi.org/10.1186/s12889-023-15962-8

Informasi Detail Dataset


Sumber dataset	https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-diseases																																							
Deskripsi awal fitur dataset	Dataset yang digunakan terdiri dari 23.496 sampel dengan 39 fitur prediktor dan satu fitur target yaitu general health. Variabel target memiliki lima kelas : Poor, Fair, Good, Very Good, dan Excellent. Namun fitur yang digunakan dalam penelitian ini dibatasi pada variabel gaya hidup, kondisi fisik, dan sosiodemografi yang berjumlah 23 fitur. Variabel riwayat penyakit tidak diikutsertakan karena bersifat sebagai konsekuensi dari kondisi kesehatan, bukan faktor penentu independen, sehingga penggunaanya dapat menyebabkan data leakage secara konseptual.																																							
	Tabel 1. Variabel Penelitian																																							
	<table><tr><th>Nama Variabel</th><th>Tipe Data</th><th>Deskripsi</th></tr><tr><td><i>General Health</i></td><td><i>Ordinal</i></td><td><i>Self-reported general health status (Poor to Excellent)</i></td></tr><tr><td>BMI</td><td><i>Float</i></td><td><i>Body Mass Index of respondent</i></td></tr><tr><td><i>SleepHours</i></td><td><i>Float</i></td><td>Rata-rata jam tidur per hari</td></tr><tr><td><i>PhysicalHealthDays</i></td><td><i>Integer</i></td><td>Jumlah hari dalam 30 hari terakhir kondisi kesehatan fisik tidak baik</td></tr><tr><td><i>MentalHealthDays</i></td><td><i>Integer</i></td><td>Jumlah hari dalam 30 hari terakhir kondisi kesehatan mental tidak baik</td></tr><tr><td><i>PhysicalActivities</i></td><td>Kategorik</td><td>Menunjukkan apakah responden melakukan aktivitas fisik</td></tr><tr><td><i>DifficultyWalking</i></td><td>Kategorik</td><td>Kesulitan berjalan atau menaiki tangga</td></tr><tr><td><i>SmokerStatus</i></td><td>Kategorik</td><td>Status kebiasaan merokok responden</td></tr><tr><td><i>ECigaretteUsage</i></td><td>Kategorik</td><td>Penggunaan rokok elektrik</td></tr><tr><td><i>AlcoholDrinkers</i></td><td>Kategorik</td><td>Status konsumsi alkohol</td></tr><tr><td><i>FluVaxLast12</i></td><td>Kategorik</td><td>Status vaksin flu dalam 12 bulan terakhir</td></tr><tr><td><i>HIVTesting</i></td><td>Kategorik</td><td>Pernah melakukan tes HIV</td></tr></table>	Nama Variabel	Tipe Data	Deskripsi	<i>General Health</i>	<i>Ordinal</i>	<i>Self-reported general health status (Poor to Excellent)</i>	BMI	<i>Float</i>	<i>Body Mass Index of respondent</i>	<i>SleepHours</i>	<i>Float</i>	Rata-rata jam tidur per hari	<i>PhysicalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan fisik tidak baik	<i>MentalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan mental tidak baik	<i>PhysicalActivities</i>	Kategorik	Menunjukkan apakah responden melakukan aktivitas fisik	<i>DifficultyWalking</i>	Kategorik	Kesulitan berjalan atau menaiki tangga	<i>SmokerStatus</i>	Kategorik	Status kebiasaan merokok responden	<i>ECigaretteUsage</i>	Kategorik	Penggunaan rokok elektrik	<i>AlcoholDrinkers</i>	Kategorik	Status konsumsi alkohol	<i>FluVaxLast12</i>	Kategorik	Status vaksin flu dalam 12 bulan terakhir	<i>HIVTesting</i>	Kategorik	Pernah melakukan tes HIV
	Nama Variabel	Tipe Data	Deskripsi																																					
	<i>General Health</i>	<i>Ordinal</i>	<i>Self-reported general health status (Poor to Excellent)</i>																																					
	BMI	<i>Float</i>	<i>Body Mass Index of respondent</i>																																					
	<i>SleepHours</i>	<i>Float</i>	Rata-rata jam tidur per hari																																					
	<i>PhysicalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan fisik tidak baik																																					
	<i>MentalHealthDays</i>	<i>Integer</i>	Jumlah hari dalam 30 hari terakhir kondisi kesehatan mental tidak baik																																					
	<i>PhysicalActivities</i>	Kategorik	Menunjukkan apakah responden melakukan aktivitas fisik																																					
	<i>DifficultyWalking</i>	Kategorik	Kesulitan berjalan atau menaiki tangga																																					
	<i>SmokerStatus</i>	Kategorik	Status kebiasaan merokok responden																																					
	<i>ECigaretteUsage</i>	Kategorik	Penggunaan rokok elektrik																																					
<i>AlcoholDrinkers</i>	Kategorik	Status konsumsi alkohol																																						
<i>FluVaxLast12</i>	Kategorik	Status vaksin flu dalam 12 bulan terakhir																																						
<i>HIVTesting</i>	Kategorik	Pernah melakukan tes HIV																																						

	<i>LastCheckupTime</i> Kategorik Waktu pemeriksaan kesehatan terakhir <i>ChestScan</i> Kategorik Riwayat pemeriksaan rontgen/scan dada <i>AgeCategory</i> Kategorik Kelompok usia <i>Sex</i> Kategorik Jenis kelamin responden <i>RaceEthnicityCategory</i> Kategorik Kategori ras/etnis responden <i>State</i> Kategorik Negara bagian tempat tinggal responden <i>WeightInKilograms</i> Float Berat badan responden dalam kilogram <i>RemovedTeeth</i> Kategorik Jumlah gigi yang telah dicabut atau hilang <i>PneumoVaxEver</i> Kategorikal Status pernah menerima vaksin <i>pneumonia</i> <i>TetanusLast10Tdap</i> Kategorikal Status vaksin tetanus dalam 10 tahun terakhir <i>HighRiskLastYear</i> Kategorikal Indikator perilaku berisiko dalam 1 tahun terakhir <i>HeightInMeters</i> Float Tinggi badan responden dalam meter																																																																		
Aspek khusus dari dataset	1. Apakah datanya sparse? Secara keseluruhan, tingkat <i>sparsity dataset</i> adalah 6.66%, yang tergolong rendah. Artinya, sebagian besar data terisi dengan baik dan tidak diperlukan penanganan khusus seperti teknik <i>sparse matrix</i> dalam pemrosesan data. 2. Bagaimana ringkasan statistik deskriptifnya? Tabel 2. Ringkasan statistik deskriptif <table><tr><th>Variabel</th><th>Mean</th><th>Std</th><th>Min</th><th>Max</th><th>Skewness</th></tr><tr><td>BMI</td><td>28.530</td><td>6.555</td><td>12.02</td><td>99.64</td><td>1.388</td></tr><tr><td><i>MentalHealthDays</i></td><td>4.383</td><td>8.387</td><td>0.00</td><td>30.00</td><td>2.123</td></tr><tr><td><i>SleepHours</i></td><td>7.064</td><td>1.502</td><td>1.00</td><td>24.00</td><td>0.765</td></tr><tr><td><i>PhysicalHealthDays</i></td><td>4.348</td><td>8.689</td><td>0.00</td><td>30.00</td><td>2.180</td></tr><tr><td><i>WeightInKilograms</i></td><td>83.074</td><td>21.448</td><td>22.68</td><td>292.57</td><td>1.076</td></tr><tr><td><i>HeightInMeters</i></td><td>1.703</td><td>0.107</td><td>0.91</td><td>2.41</td><td>0.029</td></tr></table> Berdasarkan statistik deskriptif pada Tabel 2, sebagian besar variabel memiliki mean mendekati 0 dan standar deviasi sekitar 1 karena telah distandarisasi. Nilai skewness mayoritas juga mendekati 0 sehingga distribusi data cenderung simetris atau mendekati normal. Namun, beberapa variabel seperti ‘are_mean’ dan ‘area_worst’ menunjukkan skewness positif. 3. Apakah terdapat missing value? Dari 24 variabel yang akan digunakan, 22 variabel mengandung <i>missing value</i>. Berikut tabel ringkasannya Tabel 2. Missing Value <table><tr><th>Variabel</th><th>Missing Count</th><th>Percent (%)</th></tr><tr><td><i>TetanusLast10Tdap</i></td><td>82,516</td><td>18.54</td></tr><tr><td><i>PneumoVaxEver</i></td><td>77,040</td><td>17.31</td></tr><tr><td><i>HIVTesting</i></td><td>66,127</td><td>14.86</td></tr><tr><td><i>ChestScan</i></td><td>56,046</td><td>12.59</td></tr><tr><td><i>HighRiskLastYear</i></td><td>50,623</td><td>11.37</td></tr><tr><td>BMI</td><td>48,806</td><td>10.96</td></tr><tr><td><i>FluVaxLast12</i></td><td>47,121</td><td>10.59</td></tr></table>	Variabel	Mean	Std	Min	Max	Skewness	BMI	28.530	6.555	12.02	99.64	1.388	<i>MentalHealthDays</i>	4.383	8.387	0.00	30.00	2.123	<i>SleepHours</i>	7.064	1.502	1.00	24.00	0.765	<i>PhysicalHealthDays</i>	4.348	8.689	0.00	30.00	2.180	<i>WeightInKilograms</i>	83.074	21.448	22.68	292.57	1.076	<i>HeightInMeters</i>	1.703	0.107	0.91	2.41	0.029	Variabel	Missing Count	Percent (%)	<i>TetanusLast10Tdap</i>	82,516	18.54	<i>PneumoVaxEver</i>	77,040	17.31	<i>HIVTesting</i>	66,127	14.86	<i>ChestScan</i>	56,046	12.59	<i>HighRiskLastYear</i>	50,623	11.37	BMI	48,806	10.96	<i>FluVaxLast12</i>	47,121	10.59
Variabel	Mean	Std	Min	Max	Skewness																																																														
BMI	28.530	6.555	12.02	99.64	1.388																																																														
<i>MentalHealthDays</i>	4.383	8.387	0.00	30.00	2.123																																																														
<i>SleepHours</i>	7.064	1.502	1.00	24.00	0.765																																																														
<i>PhysicalHealthDays</i>	4.348	8.689	0.00	30.00	2.180																																																														
<i>WeightInKilograms</i>	83.074	21.448	22.68	292.57	1.076																																																														
<i>HeightInMeters</i>	1.703	0.107	0.91	2.41	0.029																																																														
Variabel	Missing Count	Percent (%)																																																																	
<i>TetanusLast10Tdap</i>	82,516	18.54																																																																	
<i>PneumoVaxEver</i>	77,040	17.31																																																																	
<i>HIVTesting</i>	66,127	14.86																																																																	
<i>ChestScan</i>	56,046	12.59																																																																	
<i>HighRiskLastYear</i>	50,623	11.37																																																																	
BMI	48,806	10.96																																																																	
<i>FluVaxLast12</i>	47,121	10.59																																																																	

<i>AlcoholDrinkers</i>	46,574	10.46
<i>WeightInKilograms</i>	42,078	9.45
<i>ECigaretteUsage</i>	35,660	8.01
<i>SmokerStatus</i>	35,462	7.97
<i>HeightInMeters</i>	28,652	6.44
<i>DifficultyWalking</i>	24,012	5.39
<i>RaceEthnicityCategory</i>	14,057	3.16
<i>RemovedTeeth</i>	11,360	2.55
<i>PhysicalHealthDays</i>	10,927	2.45
<i>AgeCategory</i>	9,079	2.04
<i>MentalHealthDays</i>	9,067	2.04
<i>LastCheckupTime</i>	8,308	1.87
<i>SleepHours</i>	5,453	1.23
<i>GeneralHealth</i>	1,198	0.27
<i>PhysicalActivities</i>	1,093	0.25

Secara umum, keberadaan *missing value* dapat mempengaruhi hasil analisis maupun performa model. Oleh karena itu, diperlukan penanganan *missing value* dengan imputasi, agar dataset menjadi lebih konsisten dan siap digunakan pada tahap analisis selanjutnya.


4. Apakah datanya imbalanced?



Gambar 1. Distribusi Kelas Target

Distribusi kelas target pada variabel *generalhealth* menunjukkan bahwa data didominasi oleh kategori *Good* dengan jumlah data sekitar 7.700 data, diikuti oleh kategori *Very Good* sebanyak sekitar 7.300 data. Sementara itu kategori *Fair* dan *Excellent* memiliki jumlah yang lebih sedikit, masing-masing sekitar 3.600 dan 3.400 data, sedangkan kategori *Poor* menjadi kelas dengan jumlah paling sedikit yaitu sekitar 1.300 data. Kondisi ini menunjukkan adanya *class imbalance*, karena distribusi data antar kelas tidak merata dan beberapa kelas memiliki jumlah data jauh lebih sedikit dibanding kelas dominan, ketidakseimbangan ini dapat mempengaruhi performa model machine learning, terutama dalam mengenali kelas minoritas seperti *poor*, sehingga model cenderung lebih fokus mempelajari pola dari kelas mayoritas.

5. Bagaimana *outlier* nya?




Gambar 2. Distribusi *Outlier* Pada Fitur

Pada visualisasi *boxplot* terlihat adanya *outlier* pada setiap variabel yang ditandai dengan titik di luar *whisker*. *Outlier* paling banyak dan ekstrim muncul pada variabel BMI dan *WeightInKilograms*, yang menunjukkan adanya kelompok responden dengan berat badan serta indeks massa tubuh jauh di atas rata-rata populasi lainnya (mencapai berat hampir 300 kg dan BMI 100). Sementara itu, pada variabel *PhysicalHealthDays* dan *MentalHealthDays*, data menumpuk di angka 0 yang berarti mayoritas responden sehat, namun terdapat *outlier* konstan di angka 30 yang menunjukkan adanya pasien dengan gangguan kesehatan kronis sepanjang bulan. *Outlier* pada fitur-fitur ini masih sangat wajar karena mencerminkan variasi kondisi fisik, gaya hidup, dan riwayat penyakit yang berbeda-beda pada tiap individu, bukan karena kesalahan input data.

6. Apakah ada data yang terduplikat?

Hasil pengecekan data duplikat menunjukkan bahwa terdapat 356 baris data yang teridentifikasi sebagai duplikat dalam dataset. Keberadaan data duplikat dapat mempengaruhi hasil analisis maupun performa model karena informasi yang sama tercatat lebih dari satu kali. Oleh sebab itu, data duplikat umumnya perlu ditangani, misalnya dengan menghapus baris yang berulang agar dataset menjadi lebih bersih dan representatif.

7. Sebarannya seperti apa?




Gambar 3. Distribusi Fitur

Berdasarkan visualisasi distribusi fitur terhadap *General Health*, terlihat bahwa fitur *PhysicalHealthDays* dan *MentalHealthDays* menunjukkan perbedaan distribusi paling jelas, di mana kategori *Poor* dan *Fair* cenderung memiliki jumlah hari gangguan kesehatan fisik maupun mental yang lebih tinggi dibanding kategori *Excellent* dan *Very good*. Pada fitur BMI, kategori kesehatan yang lebih buruk memiliki distribusi BMI yang lebih tinggi dan lebih menyebar, sehingga menunjukkan hubungan antara BMI tinggi dengan kondisi kesehatan yang kurang baik, fitur *SleepHours* menunjukkan mayoritas responden tidur sekitar 6–8 jam per hari dan kategori kesehatan yang baik cenderung lebih terpusat pada rentang tersebut. Sementara itu, distribusi *WeightInKilograms* pada kategori *Poor* terlihat lebih lebar dibanding kategori lainnya, sedangkan *HeightInMeters* memiliki distribusi yang

relatif sama pada semua kategori *GeneralHealth* sehingga pengaruhnya terhadap kesehatan umum terlihat paling kecil.


8. Bagaimana korelasi antar fiturnya?



Gambar 4. Korelasi Antar Fitur

Gambar 4 menunjukkan hubungan antar variabel numerik dalam dataset. Berdasarkan hasil visualisasi, variabel '*WeightInKilograms*' dan '*BMI*' memiliki korelasi positif paling kuat, yang berarti semakin tinggi berat badan maka nilai BMI cenderung meningkat. Selain itu, '*PhysicalHealthDays*' dan '*MentalHealthDays*' juga memiliki hubungan positif sedang. Sementara variabel lain memiliki korelasi relatif lemah terhadap variabel lainnya.

8. Bagaimana korelasi fitur dengan target?



Gambar 5. Korelasi Fitur Dengan Target

Berdasarkan Gambar 5, '*PhysicalHealthDays*' memiliki korelasi negatif paling besar terhadap '*GeneralHealth*', yang menunjukkan bahwa semakin banyak hari dengan gangguan kesehatan fisik, maka kondisi kesehatan umum cenderung menurun, sama seperti '*MentalHealthDays*'. Sementara fitur lain memiliki korelasi yang sangat kecil sehingga pengaruhnya terhadap target relatif rendah.

--	--

Rencana Metode

Teknik yang digunakan	<i>Logistic Regression (baseline)</i> <i>Random Forest (ensemble bagging)</i> <i>XGBoost / Gradient Boosting (ensemble boosting)</i>
Alasan pemilihan teknik/algoritma	Logistic Regression dipilih sebagai model baseline karena memiliki kompleksitas komputasi rendah sehingga efisien dijalankan pada dataset berskala besar dengan 500.000 observasi, model bersifat linear dan mudah untuk diinterpretasikan sehingga dapat dijadikan acuan minimum performa yang harus dilampaui oleh model ensemble. Random Forest dipilih karena merupakan metode ensemble berbasis bagging yang mampu menangani data tabular berukuran besar, dan random forest sendiri terbukti robust terhadap outlier sehingga mengurangi risiko overfitting. XGBoost dipilih karena merupakan metode boosting yang memiliki performa tinggi dalam klasifikasi, mampu mempelajari pola kompleks seperti pada dataset kami fitur geometri, tekstur dan karakteristik biologis sel yang saling berkaitan sehingga <i>XGBoost</i> digunakan untuk melihat pola datanya, <i>XGBoost</i> juga digunakan untuk memperbaiki kesalahan prediksi menggunakan <i>boosting</i> sehingga nanti memiliki performa yang stabil, serta sering memberikan hasil akurasi terbaik pada data medis dan tidak seimbang.
Langkah-langkah umum pengerjaan	Tuliskan gambaran awal Anda menyelesaikan proses latih model tersebut. Metrik apa yang Anda gunakan? 1. Diagram Alur <pre> graph TD A[Indicators of Heart Disease] --> B[EDA] subgraph EDA_Box [] B1[Cek Tipe Data] B2[Distribusi Fitur & target] B3[Cek Missing Value] B4[Cek Outlier] B5[Cek Imbalance] B6[Korelasi Antar Fitur] end B --> C[Preprocessing] subgraph Preprocessing_Box [] subgraph Data_Cleaning [Data Cleaning] C1[Handling Missing Value] C2[Handling Outlier] C3[Duplikasi] end subgraph Feature_Engineering [Feature Engineering] C4[Feature Scaling] C5[Feature Selection] C6[Encoding] end end C --> D[Split Data 80:20] D --> E[SMOTE] E --> F[EDA Post-Processing] F --> G[Modeling] subgraph Modeling_Box [] G1[Logistic Regression] G2[Random Forest] G3[XGBoost] end G --> H[Evaluation and Compare Model] H --> I[Insight & visualisasi] </pre> - Memahami dan mengeksplorasi dataset melakukan pengecekan struktur data, missing value, cek outlier, cek imbalance, dan distribusi fitur. - Melakukan Preprocessing data cleaning seperti outlier, missing value dan duplikasi untuk memudahkan proses modeling, serta melakukan feature

	<i>engineering</i> seleksi fitur dan scaling untuk menyamakan bobot data yang mungkin berbeda. 3. Membagi dataset menjadi data latih (80) dan data uji (20). 4. Melakukan EDA post processing untuk melihat distribusi data setelah dilakukan <i>preprocessing</i>. 5. Melatih tiga model: Logistic Regression, Random Forest, dan XGBoost / Gradient Boosting. 6. Melakukan evaluasi performa masing-masing model pada data uji. 7. Membandingkan hasil performa ketiga model. Metrik Evaluasi yang Digunakan - Accuracy - Precision - Recall - F1-score - Confusion Matrix 8. Membuat insight dan visualisasi
--	---